

INSTITUTO FEDERAL DE EDUCAÇÃO CIENCIA E TECNOLIGIA DE
SÃO PAULO

ENGENHARIA DE CONTROLE E AUTOMAÇÃO

CAROLINA BARUSSO DE OLIVEIRA

LEONARDO LINCOL NUNES KNOELLER

**SISTEMA INTELIGENTE PARA IDENTIFICAÇÃO DE DOENÇAS
FOLIARES NA CULTURA DE SOJA**

Cubatão – SP
2024

CAROLINA BARUSSO DE OLIVEIRA
LEONARDO LINCOLN NUNES KNOELLER

**SISTEMA INTELIGENTE PARA IDENTIFICAÇÃO DE DOENÇAS
FOLIARES NA CULTURA DE SOJA**

Trabalho de Conclusão de Curso apresentado no campus Cubatão do IFSP, como requisito básico para a conclusão do Curso de Bacharelado de Engenharia de Controle e Automação.

Orientador: Prof. Dr. Arnaldo de Carvalho Junior

Coorientador: Prof. Dr. Walter Augusto Varella

Cubatão – SP
2024

Catalogação na fonte
Biblioteca Eloyza Martinez - IFSP Campus Cubatão
Dados fornecidos pelo(a) autor(a)

048s Oliveira, Carolina Barusso de

Sistema inteligente para identificação de
doenças foliares na cultura de soja / Carolina
Barusso de Oliveira, Leonardo Linconl Nunes
Knoeller. Cubatão, 2024
104 f. : il.

Trabalho de Conclusão de Curso (Bacharelado de
Engenharia de Controle e Automação) - Instituto
Federal de São Paulo - Campus Cubatão, 2024

Orientadores: Prof. Dr. Arnaldo de Carvalho
Junior e Prof. Dr. Walter Augusto Varella

1. Soja. 2. Soja - Doenças e pragas - Controle.
3. Inteligência Artificial. 4. Aprendizado do
computador. I. Knoeller, Leonardo Linconl Nunes.

ATA N.º 18/2024 - ECA-CBT/DAC-CBT/DEN-CBT/DRG/CBT/IFSP

ATA DE DEFESA DOS TRABALHOS DE GRADUAÇÃO

Aos vinte e um dias do mês de junho do ano de 2024, foi realizada, na sala 218 do Instituto Federal de Educação, Ciência e Tecnologia de São Paulo – Campus Cubatão, a apresentação da defesa do Projeto Final de Curso do(s) aluno(s) Carolina Barusso de Oliveira e Leonardo Lincon Nunes Knoeller, do curso de Bacharelado em Engenharia de Controle e Automação. O trabalho, intitulado “Sistema Inteligente para Identificação de Doenças Foliares na Cultura de Soja”, orientado pelo Professor(a) Dr. Arnaldo de Carvalho Junior e coorientado pelo Dr. Walter Augusto Varella. A Banca Examinadora foi composta pelo Professor Dr. Arnaldo de Carvalho Junior (presidente), pelo Professor Dr. Enzo Bertazini, pela Professora Dra. Flavia Daylane Tavares Luna e pela Professora Dra. Daniele de Macedo Henrique (via teleconferência). Os trabalhos foram iniciados às 13:30 pelo(a) Professor(a) presidente da banca examinadora.

Concluídas as etapas de apresentação e arguição, os examinadores da banca deliberaram sobre o trabalho e decidiram atribuir-lhe a seguinte menção:

Decisão	<input checked="" type="checkbox"/> Aprovado <input type="checkbox"/> Reprovado
Nota do PFC	<u>9,0 (nove)</u>
Parecer (comentários, restrições a atender e/ou sugestões) (usar folha anexa se necessário).	Os comentários e sugestões realizados pelos avaliadores serão encaminhados por mensagem eletrônica aos presidente da banca, que encaminhará aos bacharelados para correção da versão final do trabalho.

Nada mais havendo, encerrou-se a sessão às 15:30hs, da qual foi lavrada a presente ata, a qual segue assinada pelos componentes da Banca Examinadora e pelos alunos.

Nome	Função
Prof. Dr. Arnaldo de Carvalho Junior	Presidente
Prof. Dr. Enzo Bertazini	Membro da Banca
Profa. Dra. Flavia Daylane Tavares Luna	Membro da Banca
Profa. Daniele de Macedo Henrique	Membro da Banca
Prof. Dr. Walter Augusto Varella	Membro Suplente
Carolina Barusso de Oliveira	Discente
Leonardo Lincon Nunes Knoeller	Discente

Campus Cubatão, 21 de junho de 2024

Documento assinado eletronicamente por:

- Arnaldo de Carvalho Junior, PROFESSOR ENS BASICO TECN TECNOLOGICO, em 21/06/2024 17:30:16.
- Walter Augusto Varella, PROFESSOR ENS BASICO TECN TECNOLOGICO, em 21/06/2024 18:05:54.
- Flavia Daylane Tavares de Luna, PROFESSOR ENS BASICO TECN TECNOLOGICO, em 21/06/2024 21:37:41.
- Enzo Bertazini, PROFESSOR ENS BASICO TECN TECNOLOGICO, em 22/06/2024 06:58:26.
- Carolina Barusso de Oliveira, CB3007863 - Discente, em 23/06/2024 17:55:21.
- Leonardo Linconl Nunes Knoeller, CB3004945 - Discente, em 23/06/2024 19:36:27.

Este documento foi emitido pelo SUAP em 21/06/2024. Para comprovar sua autenticidade, faça a leitura do QRCode ao lado ou acesse <https://suap.ifsp.edu.br/autenticar-documento/> e forneça os dados abaixo:

Código Verificador: 762055

Código de Autenticação: 3c90872427



ATA N.º 18/2024 - ECA-CBT/DAC-CBT/DEN-CBT/DRG/CBT/IFSP

AGRADECIMENTOS

Gostaríamos de expressar nossa profunda gratidão a todos aqueles que, direta ou indiretamente, contribuíram para a realização deste trabalho.

Primeiramente, agradecemos aos nossos orientadores, cuja orientação e apoio foram indispensáveis para a concretização deste projeto. Sua dedicação, paciência e conhecimento nos guiaram em cada etapa, permitindo-nos superar os desafios e alcançar nossos objetivos.

Aos nossos pais, oferecemos um sincero agradecimento pelo suporte incondicional e encorajamento contínuo ao longo desta jornada. Seu amor e apoio foram fundamentais para que pudéssemos nos dedicar plenamente a este trabalho.

Manifestamos também nossa gratidão a todos aqueles que, generosamente, nos ajudaram ao longo do caminho, seja esclarecendo dúvidas, oferecendo sugestões, respondendo a questionários ou disponibilizando seu tempo.

RESUMO

Este Trabalho apresenta o desenvolvimento de um sistema inteligente e portátil para a identificação de doenças foliares na cultura da soja. O sistema utiliza técnicas de Inteligência Artificial (IA) e Visão Computacional para auxiliar agricultores no diagnóstico e tomada de decisões para o manejo eficiente da lavoura, contribuindo para o aumento da produtividade e redução de perdas. Um modelo de rede neural convolucional (CNN) foi desenvolvido na plataforma no-code Edge Impulse, alcançando uma acurácia de 87,7% na classificação de cinco classes de doenças prevalentes no Brasil: Mancha Alvo, Ferrugem Asiática, Mancha, Olho-de-Rã, Deficiência de Potássio e a classe Saudável. Para compreender as dificuldades enfrentadas pelos produtores no campo, um questionário foi aplicado abordando temas como a adoção de tecnologia no agronegócio e o manejo de doenças na lavoura. O protótipo do sistema integra o microcontrolador ESP32-CAM para a captura de imagens das folhas, o display OLED para a visualização das informações de diagnóstico e o módulo GPS Ublox NEO-6M para o registro da localização geográfica, permitindo a criação de mapas de incidência de doenças. Adicionalmente, um dashboard interativo foi desenvolvido na plataforma Power BI, juntamente com um relatório automatizado, para fornecer aos agricultores informações detalhadas sobre a incidência de doenças na lavoura, além de um guia prático com um checklist para auxiliar na tomada de decisões e no manejo fitossanitário da cultura.

Palavras-chave: Soja, doenças foliares, inteligência artificial, aprendizado de máquina, Edge Impulse.

ABSTRACT

This work presents the development of an intelligent and portable system for the identification of foliar diseases in soybean crops. The system utilizes Artificial Intelligence (AI) and Computer Vision techniques to assist farmers in diagnosis and decision-making for efficient crop management, contributing to increased productivity and reduced losses. A convolutional neural network (CNN) model was developed on the no-code Edge Impulse platform, achieving an accuracy of 87.7% in classifying five prevalent diseases in Brazil: Target Spot, Asian Rust, Brown Spot, Frog Eye Leaf Spot, Potassium Deficiency, and the Healthy class. To understand the challenges faced by farmers in the field, a questionnaire was conducted addressing topics such as technology adoption in agribusiness and disease management in crops. The system prototype integrates the ESP32-CAM microcontroller for image capture of leaves, an OLED display for visualizing diagnostic information, and the Ublox NEO- 6M GPS module for recording geographical location, allowing the creation of disease incidence maps. Additionally, an interactive dashboard was developed on the Power BI platform, along with an automated report, to provide farmers with detailed information on disease incidence in the crop, as well as a practical guide with a checklist to assist in decision-making and phytosanitary management of the crop.

Keywords: Soybean, leaf diseases, artificial intelligence, machine learning, Edge Impulse

LISTA DE FIGURAS

Figura 1 - Protocolo de Busca por Palavra-chave	17
Figura 2 - Tipos de Documentos	18
Figura 3 - Funil de Critérios de Exclusão	18
Figura 4 - Estrutura rede neural	19
Figura 5 - Gráfico de uma ReLU	20
Figura 6 - Filtros e Convolução de Imagens	22
Figura 7 - Trabalhos Selecionados	25
Figura 8 - Exemplo de Imagens da Base	26
Figura 9 - Distribuição das Amostras	27
Figura 10 - Esquema de Bibliotecas <i>Edge Impulse</i>	28
Figura 11 - Fluxo de trabalho do <i>Edge Impulse</i>	29
Figura 12 - Coleta de Dados	30
Figura 13 - Identificação do Tipo do Projeto	31
Figura 14 - Impulso de Criação	31
Figura 15 - Rede Neural Configurações	32
Figura 16 - Implantação do Modelo	33
Figura 17 - Proporção de Treinamento / Teste	36
Figura 18 - Visualização Amostra Classe Olho de Rã	36
Figura 19 - Gráfico de Dispersão	37
Figura 20 - Criação do Impulso	38
Figura 21 - Definição dos Parâmetros de cor da Imagem	38
Figura 22 - Configurações de Treinamento do Primeiro Modelo	39
Figura 23 - Configurações de Treinamento do Segundo Modelo	40
Figura 24 - Biblioteca para Arduino	41
Figura 25 - Adicionando Biblioteca ao Arduino IDE	42
Figura 26 - Escolhendo Biblioteca no Arduino IDE	42
Figura 27 - Exemplos da Biblioteca Arduino IDE	43
Figura 28 - Exemplo Arduino IDE	43
Figura 29 - Fluxograma de Funcionamento	44
Figura 30 - Diagrama de Blocos das Conexões Básicas ESP32-CAM com GPS e display ..	45
Figura 31 - Protótipo das Conexões Básicas dos Componentes	46
Figura 32 - Pinagem do módulo ESP32 CAM	47
Figura 33 - Apresentação das duas faces da placa do ESP32 CAM	47
Figura 34 - Módulo de gravação com interface serial USB-TTL	48
Figura 35 - Módulo auxiliar para a gravação do ESP32 - CAM	48
Figura 36 - Triangulação a Partir de Satélites	50
Figura 37 - Módulo GPS GY NEO6MV2	50
Figura 38 - Arquitetura interna do módulo GY-NEO6MV2	51
Figura 39 - Pinagem e Dimensionamento OLED .96"	52
Figura 40 - Bateria de Lítio	54
Figura 41 - Figura Bateria SD303040 Com Seus Terminais Divididos	55
Figura 42 - Case do Dispositivo Desenvolvido	56
Figura 43 - Tela Inicial <i>Power BI</i>	57
Figura 44 - <i>Dashboard</i> para Análise dos Dados	58
Figura 45 - Cartilhas sobre as doenças de soja	59
Figura 46 - Cartilha doença Mancha Alvo	60
Figura 47 - Produto Abacus HC para Mancha Alvo	61
Figura 48 - Cartilha Ferrugem Asiática	61
Figura 49 - Cartilha Deficiência de Potássio	62
Figura 50 - Cartilha Olho de Rã	62
Figura 51 - Relatório para análise geral	63
Figura 52- Armazenamento dos Arquivos	64

Figura 53- Atualização do Dados	65
Figura 54 - Matriz de confusão primeiro modelo	68
Figura 55 - Matriz de confusão	69
Figura 56 - Gráfico de Dispersão dos Resultados.....	70
Figura 57 - Amostra com classificação errada	71
Figura 58 - Resposta retirada do questionário sobre as doenças e região.....	72
Figura 59 - Impacto Financeiro	73
Figura 60 - Tecnologias Aplicadas.....	73
Figura 61 - Resultado da Montagem.....	74
Figura 62 - Teste do Modelo	75
Figura 63 - Cartão de Memória	76
Figura 64 - Pasta do Cartão de Memória	77
Figura 65 - Exemplo de Figura Classificada.....	78
Figura 66 - Base Excel.....	79
Figura 67 - Atualização de Dados BI.....	80
Figura 68 - <i>Dashboard</i> do teste	81
Figura 69 - Relatório gerado com os dados de teste.....	82

LISTA DE TABELAS

Tabela 1 - Número de Imagens por Classe.....	27
Tabela 2 - Diferenças entre Computação na Borda e na Nuvem	35
Tabela 3 - Especificações do Módulo ESP32 CAM.....	48
Tabela 4 - Especificações Técnicas do Módulo GPS GYNEO6MV2.....	51
Tabela 5 - Descrição Técnica do Oled .96"	53
Tabela 6 - Características Bateria Recarregável.....	54
Tabela 7 - Matriz de Confusão.....	83

LISTA DE ABREVIASÕES

API	<i>Application Programming Interface</i> (Interface de Programação de Aplicações)
BI	<i>Business Intelligence</i> (Inteligência do Negócio)
CBOR	Representação Concisa de Objetos Binários.
CNN	<i>Convolutional Neural Network</i> (Rede Neural Convolucional)
CNPq	Conselho Nacional de Desenvolvimento Científico e Tecnológico.
CSV	<i>Comma Separated Value</i> (Valores Separados por Vírgula)
ESP32 CAM	Placa de desenvolvimento baseada no microcontrolador ESP32 com uma câmera integrada.
GPIO	<i>General Purpose Input/Output</i> (Entrada/Saída de Uso Geral)
GPS	<i>Global Positioning System</i> (Sistema de Posicionamento Global)
IDE	<i>Integrated Development Environment</i> (Ambiente de Desenvolvimento Integrado - Arduino).
IoT	<i>Internet of Things</i> (Internet das Coisas)
ML	<i>Machine Learning</i> (Aprendizado de Máquina)
ONNX	Troca de Redes Neurais Abertas.
PSR	Processo de <i>Software</i> em Regime.
ReLU	<i>Rectified Linear Unit</i> (Unidade Linear Retificada)
RNA	Rede Neural Artificial.
RNN	<i>Recurrent Neural Network</i> (Rede Neural Recorrente)
RX	<i>Receiver</i> (Receptor)
SAR Images	Imagens de Radar de Abertura Sintética.
TX	<i>Transmitter</i> (Transmissor)
USB-TTL - USB - Transistor	USB - Lógica Transistor-Transistor, usada para comunicação serial via USB.
USDA NASS	Departamento de Agricultura dos Estados Unidos - Serviço Nacional de Estatísticas

SUMÁRIO

RESUMO.....	6
ABSTRACT.....	7
1. INTRODUÇÃO.....	14
1.1. Justificativa.....	15
1.2. Objetivos	16
1.2.1 Objetivo Geral	16
1.2.2 Objetivo Específico	16
1.3. Estrutura do trabalho.....	16
2. REVISÃO DA LITERATURA.....	17
2.1. Protocolo de pesquisa para revisão da literatura	17
2.2. Análise da literatura.....	19
3. MATERIAIS E MÉTODOS.....	26
3.1. Seleção da base de dados.....	26
3.2. Desenvolvimento da rede neural com plataforma <i>no-code</i>	28
3.3. <i>Tiny ml</i> com ia na borda	34
3.4. Desenvolvimento do modelo	35
3.5. Desenvolvimento do <i>hardware</i> do protótipo	45
3.5.1 Diagrama de blocos do protótipo	45
3.5.2 Descrição do módulo esp32 – <i>cam</i>	46
3.5.3 Descrição da conexão gps utilizada no protótipo	49
3.5.4 Descrição do lcd <i>display oled</i> .96" 128x64.....	52
3.5.6 Montagem eletrônica do protótipo.....	54
3.6. Interface de analise de dados	57
3.7. Relatório para analise geral das amostras	63
3.8. Formulário sobre manejo de doenças e práticas culturais	66
4. RESULTADOS OBTIDOS.....	68
4.1. Acurácia alcançada pelo modelo da rede neural	68
4.2. Analise das respostas do formulário	71
4.3. Resultado final da montagem.....	74
4.4. Testes de desempenho.....	75
5. CONSIDERAÇÕES FINAIS	84
6. REFERENCIAS	86
ANEXOS	93
APÊNDICE.....	94

1. INTRODUÇÃO

A relevância econômica da soja e sua crescente demanda global colocam os agricultores em constante preocupação com a saúde das plantas deste cultivo vital, especialmente diante da projeção da ONU de que a população mundial atingirá 9 bilhões até 2050 (ONU, 2019).

A soja desempenha um papel fundamental na produção de alimentos e rações, tornando sua condição crucial tanto para a segurança alimentar quanto para a estabilidade econômica (ORUMA, MISRA, FERNANDEZ, 2021) e as doenças foliares representam um dos maiores desafios para a produção de soja.

A ferrugem asiática, identificada pela primeira vez no Brasil em 2001, é considerada a principal ameaça às áreas de cultivo no país devido à sua rápida disseminação (EMBRAPA, 2024). As folhas infectadas pela doença amarelam, secam e caem prematuramente, resultando em grãos menores, comprometimento da qualidade e perdas significativas na produção (MARKELL, 2021).

A crescente incidência da mancha-alvo, caracterizada por manchas circulares de cor castanha com um ponto central, semelhantes a alvos (HENNING *et al.*, 2014), é preocupante devido ao aumento do cultivo de variedades suscetíveis e à limitada eficácia dos fungicidas mais comumente utilizados. Essa doença tem impactado regiões como Mato Grosso, Goiás, Minas Gerais, Tocantins, Maranhão e Piauí, causando perdas que variam entre 15% e 25% (EMBRAPA, 2024).

A mancha olho-de-rã, causada pelo fungo Cercospora sojina, é uma doença foliar prevalente na soja brasileira (EMBRAPA, 2024). Suas lesões, com centro marrom e halo amarelado, lembram olhos de rã (HENNING *et al.*, 2014). Alta umidade e temperaturas amenas, comuns no enchimento de grãos, favorecem a doença (EMBRAPA, 2024). A desfolha precoce reduz a fotossíntese, causando perdas de 10% a 40%.

A deficiência de potássio, nutriente essencial, predispõe a soja à mancha olho-de-rã (EMBRAPA, 2024). O potássio regula a abertura dos estômatos, por onde o fungo entra (BROWN, 2022). Plantas deficientes têm estômatos mais abertos, facilitando a infecção. O potássio também participa da síntese de proteínas e enzimas de defesa.

Diante desse cenário, as tecnologias emergentes da Indústria 4.0 oferecem uma nova perspectiva para o manejo fitossanitário. A integração de algoritmos de aprendizado de máquina e visão computacional possibilitam a detecção precoce de doenças foliares, e com isso possibilitando intervenção rápida e direcionada (REIS,2020).

Esses sistemas baseados em inteligência artificial têm o potencial de revolucionar a gestão nas plantações de soja, promovendo uma abordagem mais eficaz e sustentável para proteger as colheitas e garantir a segurança alimentar (SU e WANG, 2022).

Atualmente, uma gama diversificada de ferramentas está à disposição para facilitar o treinamento de redes neurais em diversas linguagens de programação. No entanto, um método conhecido como *No-Code* (Sem Código), está ganhando cada vez mais popularidade. Essa abordagem elimina a necessidade de conhecimento profundo em linguagens de programação, simplificando e otimizando o processo de desenvolvimento (HURLBURT, 2021).

No Anexo A, encontra-se um capítulo de livro publicado nos Anais do Workshop de Micro-ondas (WMO) de 2023, organizado pelo (LABORATÓRIO MAXWELL, 2023). Este trabalho apresenta um estudo preliminar sobre o desenvolvimento de inteligência artificial para a classificação de folhas de soja em duas classes: saudáveis e doentes.

1.1. Justificativa

A aplicação da classificação de imagens se revela particularmente valiosa no contexto da agricultura moderna. Esta abordagem permite uma detecção ágil e precisa das folhas saudáveis e das afetadas por doenças, disponibilizando informações cruciais que capacitam os agricultores a tomarem decisões estratégicas para o manejo de suas plantações (WANG, 2020).

Ao automatizar grande parte do processo de diagnóstico fitossanitário, a IA não apenas proporciona uma detecção mais rápida e precisa de doenças foliares, mas também libera os agricultores de tarefas manuais intensivas, permitindo que se concentrem em outras atividades cruciais para a produção agrícola (FARMONOV *et al.*,2023).

Assim, a utilização da inteligência artificial neste estudo representa não apenas um avanço significativo na gestão da saúde das plantas na agricultura contemporânea, mas também promove práticas agrícolas mais eficientes, sustentáveis e resilientes (COSTA,2020).

1.2. Objetivos

Nesta seção são apresentados o Objetivo Geral e os Objetivos Específicos.

1.2.1 Objetivo Geral

Desenvolver um sistema de classificação de doenças na cultura de soja, com uso de técnicas de Inteligência Artificial para coletar imagens de folhas de soja, e identificar a existência de doenças foliares, e caso positivo, apresentar os procedimentos de tratamento a serem adotados pelos produtores.

1.2.2 Objetivo Específico

- a. Desenvolver um modelo de Rede Neural que após treinamento e testes apresente uma acurácia superior a 85%;
- b. Desenvolver um *software* para a coleta de imagens, processamento, armazenamento e apresentação aos usuários de informações sobre a plantação de soja e ações de minimização e tratamento das doenças.
- c. Desenvolver um sistema de *hardware* para a coleta de imagens e disponibilização em ambiente de análise.

1.3. Estrutura do trabalho

Este trabalho apresenta cinco capítulos que contemplam todo o desenvolvimento do sistema inteligente para detecção de doenças foliares em plantas de soja, que pode ser utilizado para automatizar grande parte do processo de diagnóstico fitossanitário. Assim, o capítulo 1 apresenta a introdução do assunto abordado e os objetivos propostos. O capítulo 2 apresenta a revisão da literatura com o protocolo de pesquisa adotado, análise da literatura, detecção de doenças foliares em soja e classificação de imagens com uso de redes neurais, discorrendo sobre o atual estado da arte. O capítulo 3 apresenta Materiais e Métodos. O capítulo 4 apresenta os resultados obtidos e o capítulo 5, apresenta as considerações finais.

2. REVISÃO DA LITERATURA

Este capítulo apresenta a revisão da literatura sobre doenças na cultura de soja e uso de tecnologias de Inteligência Artificial.

2.1. Protocolo de pesquisa para revisão da literatura

A base de dados selecionada para a pesquisa foi a *Scopus* (SCOPUS, 2024), que agrupa grande parte dos periódicos de alto fator de impacto, e acessível através do site *periódicos* (PERIODICOS, 2024), que é disponibilizado pelo CNPq, o que possibilita o acesso aos artigos.

As palavras-chave utilizadas foram: “*soybean*”, “*image classification*” e “*neural network*”, com o algoritmo de busca e resultados mostrados na Figura 1.

Figura 1 - Protocolo de Busca por Palavra-chave

The screenshot shows the Scopus search interface with the following search query:

```

Search within Article title, Abstract, Keywords: soybean
AND
Search within Article title, Abstract, Keywords: "image classification"
AND
Search within Article title, Abstract, Keywords: "neural network"
  
```

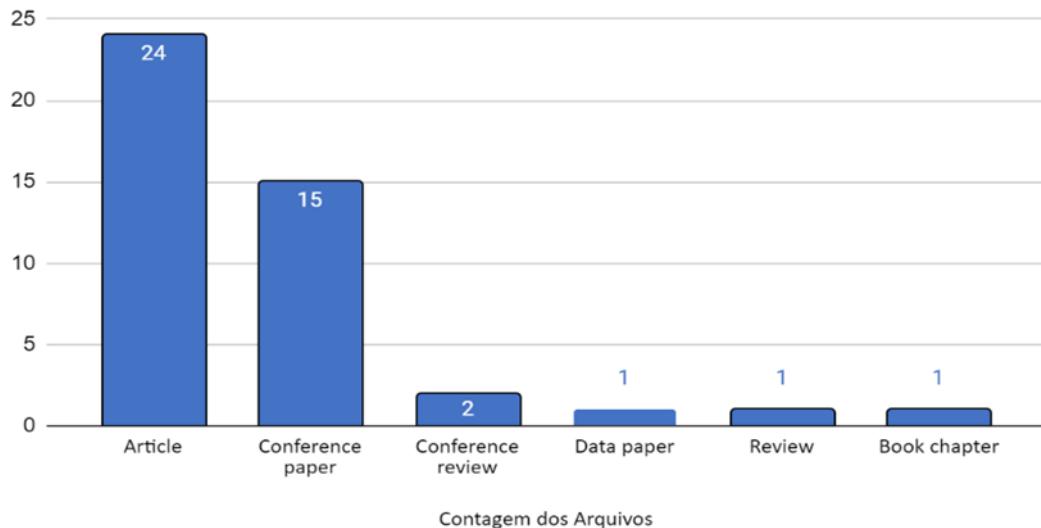
Below the search bar, there are buttons for 'Save search', 'Set search alert', '+ Add search field', 'Reset', and a 'Search' button. The results section shows 44 documents found, with a table listing the first two articles:

Rank	Article Title	Authors	Source	Year	Citations
1	Soybean seed vigor classification through an effective image learning-based approach	Souza, M., Horikoshi, W.C., Saito, P.T.M., Bugatti, P.H.	Multimedia Tools and Applications, 83(5), pp. 13113–13136	2024	0
2	A deep learning framework for crop mapping with reconstructed Sentinel-2 time series images	Feng, F., Gao, M., Liu, R., Yao, S., Yang, G.	Computers and Electronics in Agriculture, 213, 106007	2023	1

Fonte: Dos autores, (2024)

Para o início de análise dos documentos encontrados conforme a Figura 2 foram excluídos artigos em chinês (4), *Book Chapter* (1), *Conference Review* (2), *Review* (1) e *Data Paper* (1), resultando em 35 documentos para a segunda análise.

Figura 2 - Tipos de Documentos

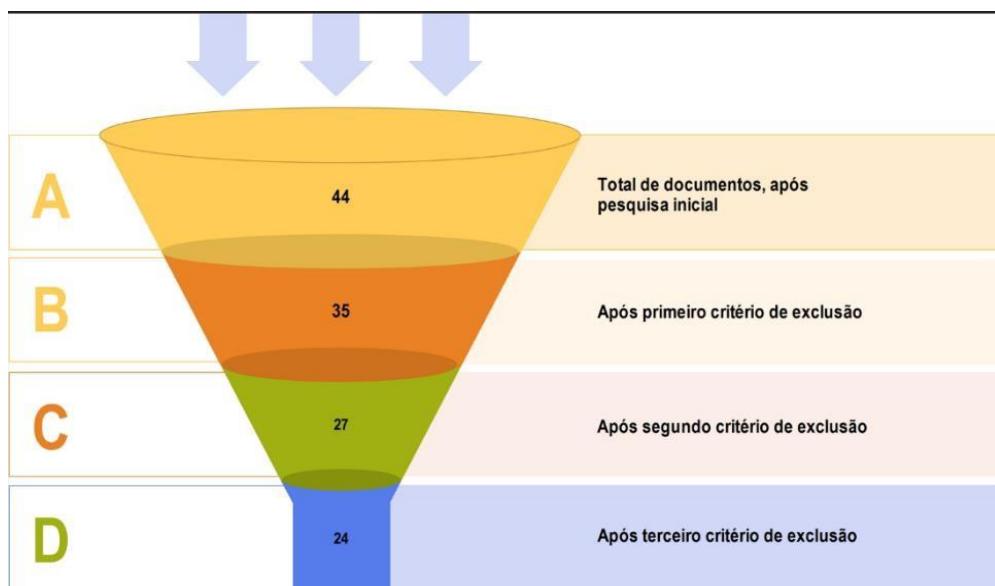


Fonte: Dos autores, (2024)

O segundo critério de exclusão foi com relação ao título do artigo, que não apresentava relação com o objetivo da pesquisa, sendo eliminados 8 documentos, sobrando 27 documentos para a próxima etapa.

O terceiro critério de exclusão foi a leitura integral do artigo, o que eliminou 3 artigos, e assim sendo sobraram 24 artigos para análise de contribuição no desenvolvimento do trabalho. A Figura 3 apresenta de forma gráfica a etapa de seleção dos artigos.

Figura 3 - Funil de Critérios de Exclusão



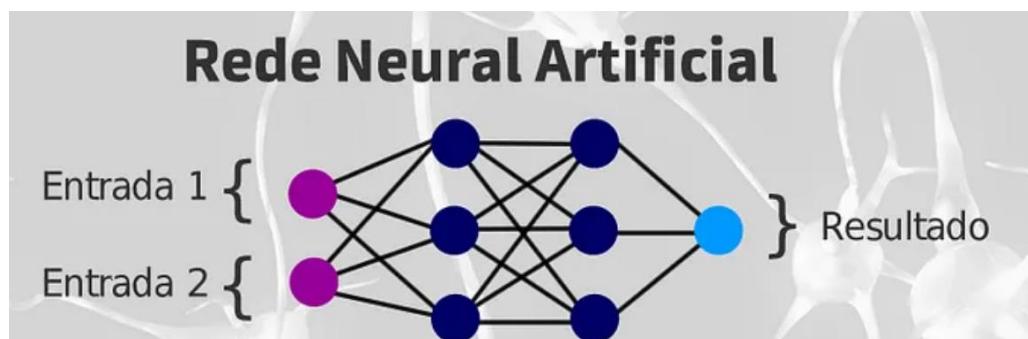
Fonte: Dos autores, (2024)

2.2. Análise da literatura

As Redes Neurais Artificiais (RNA) são um modelo matemático inspirado no cérebro humano, essenciais na Inteligência Artificial. Elas consistem em neurônios interconectados em camadas, que processam informações através de cálculos ponderados para gerar saídas. Durante o treinamento com algoritmos de aprendizado, os pesos das conexões entre neurônios são ajustados para otimizar o desempenho da rede, formando as redes neurais artificiais (JAFARI; HAGAN, 2018).

Redes neurais são compostas por neurônios artificiais que realizam operações matemáticas inspiradas por neurônios biológicos, formando o núcleo das redes neurais artificiais como visto na Figura 4 com as entradas e saída do resultado. Embora não tenham a mesma complexidade do cérebro humano, as RNAs compartilham duas semelhanças fundamentais com redes neurais biológicas: a capacidade de descrever seus elementos básicos usando dispositivos computacionais simples, e a função da rede é determinada pelas conexões entre os neurônios (HAGAN *et al.*, 2014).

Figura 4 - Estrutura rede neural

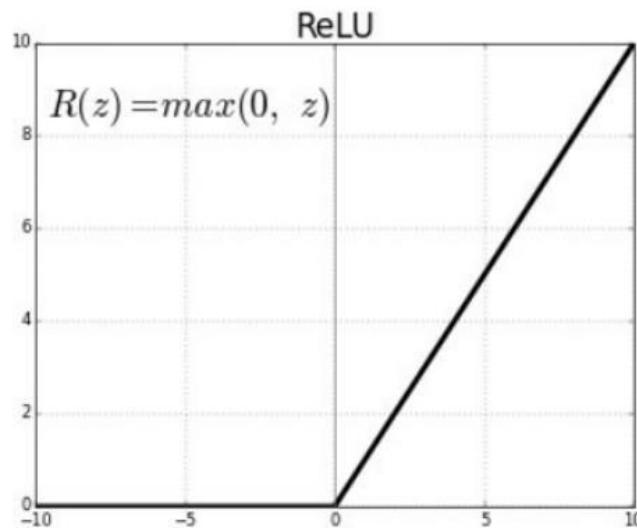


Fonte: GRÜBLER, M. (2019).

Os neurônios por unidade retificadora linear (*rectified linear unit* – ReLU), por sua vez, são uma função de ativação comumente utilizada em RNAs, como ocorre no Edge Impulse (EDGE IMPULSE, 2024). Essa função introduz não-linearidade nas operações da rede, permitindo que a RNA aprenda padrões e relações complexas nos dados de entrada de forma rápida (BOTOEVA, *et al.*, 2020). A Figura 5 ilustra a função ReLU que é definida como $R(z) = \max(0, z)$ ou seja, se o

valor de entrada for positivo, o neurônio ativa e transmite o sinal adiante; caso contrário, ele permanece inativo.

Figura 5 - Gráfico de uma ReLU



Fonte: BOTOEVA, et al., (2020).

Uma Rede Neural Convolucional (*convolutional neural network - CNN*) é um tipo de rede neural artificial especialmente projetada para processar dados visuais, como imagens. Ela funciona através de camadas de convolução, onde filtros são aplicados às entradas para extrair características importantes (SU e WANG, 2022). Essas características são então passadas por camadas de pooling para reduzir a dimensionalidade e, finalmente, conectadas a camadas densas, que realizam a classificação ou ação desejada.

Estudos como os de (SIDIKE et al., 2019) demonstram o potencial da combinação de imagens de satélite e Google Street View com aprendizado profundo para classificar elementos agrícolas na cultura da soja com alta precisão. Essa abordagem, juntamente com a pesquisa proposta por (YAN e RYU, 2021), abre caminho para a identificação precoce de doenças e pragas, permitindo intervenções direcionadas e otimizando o manejo das plantações.

Segundo Gcharge e Singh (2016), a exploração do uso de técnicas de aprendizado profundo e aumento de dados para identificar padrões de doenças em folhas de soja resulta em uma alta eficácia. Essa pesquisa contribui para o

desenvolvimento de sistemas automatizados de diagnóstico de doenças, que podem auxiliar os agricultores na tomada de decisões mais precisas e eficientes.

Um algoritmo inovador de reconhecimento de imagens, realizado por (XIN e WANG, 2020), utiliza o aprendizado por migração e redes neurais convolucionais profundas para identificar pragas em plantas de soja com alta precisão e robustez. Essa técnica apresenta um grande potencial para reduzir os danos causados por pragas e aumentar a produtividade da cultura.

A fim de prever a produção de soja, (ALTYLAR e TERLİKSİZ, 2019) desenvolveram um modelo de redes neurais profundas utilizando imagens de satélite e dados do USDA NASS. Essa ferramenta pode ser utilizada para identificar áreas com maior risco de doenças e pragas, permitindo ações preventivas e otimizando o uso de recursos.

Redes neurais convolucionais podem ser utilizadas eficientemente na detecção de plantas daninhas com imagens de drones e UAVs (FERREIRA *et al.*, 2017). Essa técnica permite a identificação precisa e oportuna de plantas daninhas, possibilitando o controle eficiente e direcionado, como proposto por (SIVAKUMAR *et al.*, 2020), o que contribui para a otimização da produção e a redução do uso de herbicidas.

O uso do Mask R-CNN para segmentar imagens de sementes de soja é bastante utilizado por (HUANG *et al.*, 2022), nele se nota a possibilidade de classificação precisa e automatizada das sementes. Essa técnica apresenta um grande potencial para aumentar a eficiência e a qualidade dos processos de seleção de sementes.

No trabalho de Skakun *et al.* (2016) combinam imagens de radar multitemporais com imagens ópticas e redes neurais em comitê para classificar culturas na Ucrânia com alta precisão, incluindo a soja. Essa abordagem demonstra o potencial de diferentes tipos de imagens para a identificação precisa de culturas, o que pode ser utilizado para o monitoramento da produção e o planejamento agrícola.

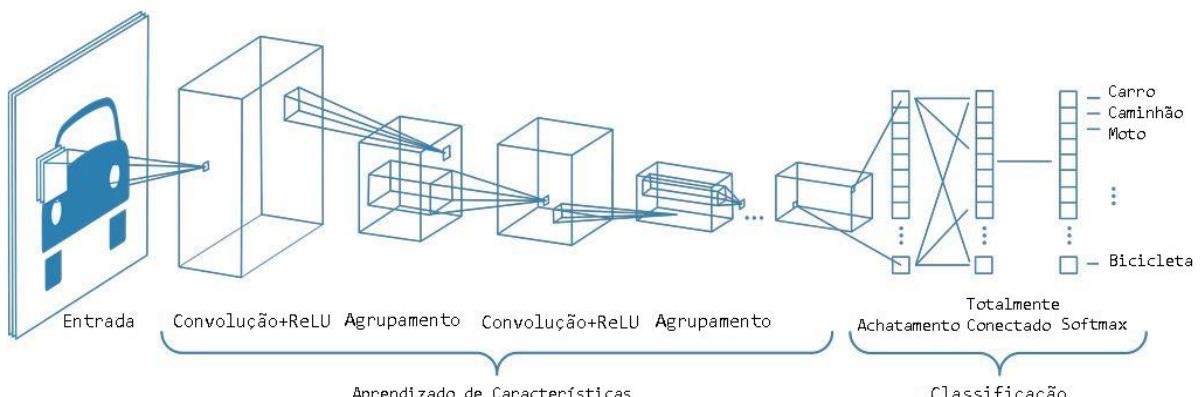
O modelo OB-ConvLSTM, proposto por (LUO *et al.*, 2023) integra OBIA e ConvLSTM para classificar culturas em imagens de sensoriamento remoto com alta

acurácia. Essa técnica apresenta um grande potencial para a classificação precisa de culturas em larga escala, o que pode ser utilizado para o monitoramento da saúde das plantações e a gestão da produção agrícola.

Para realização de seu estudo, diversas técnicas de redes neurais convolucionais foram analizadas para fenotipagem de culturas, destacando a importância da qualidade das imagens e da implementação de CNNs robustas em dispositivos móveis para a agricultura de precisão. Su e Wang (2022) contribuem para o desenvolvimento de sistemas automatizados de fenotipagem de culturas, que podem auxiliar os agricultores na avaliação da saúde das plantações.

A Figura 6 ilustra como funciona a implementação das CNNs, exemplificando uma rede com muitas camadas convolucionais. Filtros são aplicados a cada imagem de treinamento em diferentes resoluções, e a saída de cada imagem convoluída é usada como entrada para a próxima camada.

Figura 6 - Filtros e Convolução de Imagens



Fonte: Adaptado de MATHWORKS, 2022.

Um banco de dados abrangente foi desenvolvido por (LIN *et al.*, 2023) fornecendo um conjunto com mais de 5500 imagens de sementes de soja categorizadas. Esse conjunto de dados é fundamental para o desenvolvimento e treinamento de algoritmos de aprendizado de máquina, possibilitando avanços na classificação de sementes e na compreensão da saúde das plantas de soja.

A pesquisa de Kussul *et al.* (2014) investiga o uso de imagens de radar SAR para classificar culturas na Ucrânia, incluindo a soja. Este estudo destaca o potencial

das imagens SAR para a identificação de doenças em plantas de soja, complementando o uso de outros tipos de imagens.

Buscando mapear culturas agrícolas utilizando imagens de séries temporais, (FENG *et al.*, 2023) propõem um *framework* de aprendizado profundo. Essa abordagem oferece uma perspectiva valiosa para a identificação de doenças em soja, pois possibilita o monitoramento contínuo da saúde das plantações ao longo do ciclo de cultivo.

Discutindo técnicas de aprendizado de máquina e profundo para detecção de plantas daninhas em plantações de soja, (DHARMADHIKARI *et al.*, 2023) destacam a importância do controle preciso de plantas daninhas para a otimização da produtividade agrícola. Essa pesquisa contribui significativamente para o desenvolvimento de sistemas automatizados de detecção eficientes.

Por fim, o estudo de (BEVERS *et al.*, 2022) propõe um classificador automatizado de imagens digitais de doenças de soja. Essa ferramenta automatizada pode auxiliar os agricultores no diagnóstico precoce de doenças, permitindo a aplicação de medidas de controle mais assertivas e reduzindo o uso de pesticidas.

O aprendizado de máquina (ou *machine learning*) é um campo da inteligência artificial que permite que sistemas computacionais aprendam e melhorem seu desempenho automaticamente através da análise de dados. Ao contrário da programação tradicional, onde cada passo é explicitamente definido, os algoritmos de *machine learning* identificam padrões e relações nos dados, extraíndo conhecimento sem serem explicitamente instruídos (SHINDE e SHAH, 2018).

As ferramentas "No-Code" são plataformas que permitem a criação de modelos de *machine learning* (Aprendizado de máquina) e treinamento de redes neurais sem a necessidade de escrever código manualmente. Elas oferecem interfaces gráficas intuitivas, onde os usuários podem arrastar e soltar componentes, configurar parâmetros e definir arquiteturas de modelos sem escrever uma única linha de código (HURLBURT, 2021)

Essas ferramentas como exemplo do Edge Impulse usam uma combinação de técnicas de automação e algoritmos pré-definidos para simplificar tarefas

complexas, como pré-processamento de dados, seleção de algoritmos, ajuste de hiper parâmetros e avaliação de desempenho do modelo. (EDGE IMPULSE,2024).

Conhecido popularmente como *TinyML*, é a abreviação de *Tiny Machine Learning*, que se refere à aplicação de técnicas de aprendizado de máquina em dispositivos de baixa potência, como microcontroladores e sensores embarcados (NICOLAS, NAILA e AMAR, 2022). Essa abordagem visa capacitar esses dispositivos a realizar tarefas de inferência e tomada de decisão localmente, sem depender de conexões de rede ou de servidores externos. O *TinyML* é essencial para aplicações de Internet das Coisas (*internet of things - IoT*) em que a eficiência energética e a capacidade de processamento são cruciais, permitindo a implementação de sistemas inteligentes em dispositivos com recursos limitados.

A integração de *TinyML* e software para leitura em tempo real viabiliza a implementação eficiente de sistemas de classificação de imagens no campo. Essa abordagem permite o processamento local de dados em dispositivos de baixa potência, agilizando o diagnóstico fitossanitário em áreas remotas com conectividade limitada (ZHANG, 2021).

O estudo de (BHATTACHARYA e PANDEY, 2024) ressalta a aplicação de modelos *TinyML* de baixo consumo de energia para monitorar a qualidade do solo na agricultura. Essa abordagem se conecta diretamente com a pesquisa sobre identificação de doenças em plantas de soja por meio de imagens, evidenciando como a tecnologia pode melhorar as práticas agrícolas. Os insights do artigo destacam o potencial dos modelos *TinyML* para aprimorar a gestão do solo, permitindo decisões rápidas e informadas pelos agricultores, o que contribui para a otimização do cultivo e da produção agrícola.

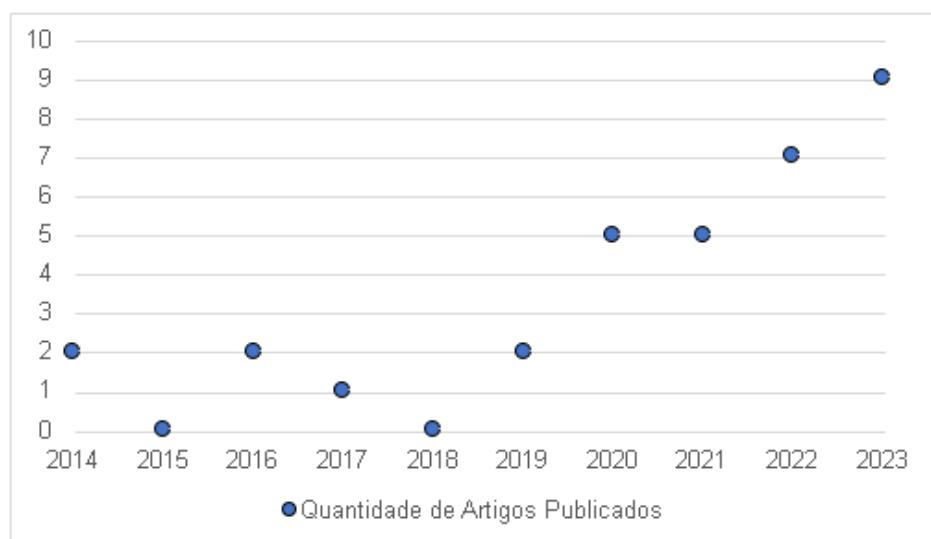
Para detectar frutas em fazendas inteligentes, o artigo de (NICOLAS, NAILA e AMAR, 2022) propõe um sensor inteligente usando *TinyML*, reduzindo a transferência de dados e melhorando a eficiência energética. O sistema envolve coleta de dados, tomada de decisões na nuvem e comunicação das ações para um executor, como um agricultor, permitindo detecção de frutas e ações específicas de forma eficiente e com baixo consumo de energia.

A utilização de sensores inteligentes com capacidade de processamento local pode agilizar a detecção de doenças nas plantações de soja, permitindo decisões rápidas para o controle e prevenção de problemas fitossanitários.

Além disso, a abordagem eficiente de comunicação e economia de energia apresentada nos artigos pode inspirar estratégias semelhantes para otimizar a captura e classificação de imagens em plantações de soja, contribuindo para aprimorar a gestão agrícola e a segurança alimentar.

A Figura 7 apresenta a distribuição dos anos de publicação dos trabalhos selecionados no campo da agricultura de precisão, com foco específico em tecnologias de detecção e diagnóstico de doenças em culturas de soja.

Figura 7 - Trabalhos Selecionados



Fonte: Dos Autores , (2024).

Observa-se um aumento gradual no número de publicações a partir de 2019, indicando um crescente interesse e investimento em pesquisas nessa área. O pico de publicações em 2023 sugere um foco intenso em pesquisa e desenvolvimento, possivelmente impulsionado pelo reconhecimento da importância crítica da segurança alimentar e da eficiência agrícola.

3. MATERIAIS E MÉTODOS

Nesse capítulo, é abordada a base de dados utilizada para o treinamento da rede neural, assim como a ferramenta de treinamento, o desenvolvimento do modelo e sua implementação no protótipo de *hardware*, juntamente com sua descrição.

3.1. Seleção da base de dados

Para treinar um modelo de rede neural, é fundamental possuir uma base de dados confiável e de alta qualidade. A base selecionada, desenvolvida por (BEVERS, SIKORA, HARDY, 2022), consiste em imagens de folhas de soja. Essas imagens foram coletadas durante as temporadas de 2020 e 2021, em campos localizados na cidade de Tallahassee, Alabama. O conjunto de dados conta com 10.722 imagens, distribuídas em oito categorias de imagens.

As sete doenças presentes nesta base incluem: mancha bacteriana, queima das folhas por cercospora, míldio, olho-de-rã causada pela Cercospora sojina, deficiência de potássio, ferrugem da soja e mancha-alvo (BEVERS, SIKORA, HARDY, 2022).

A Figura 8, mostra as características que essas doenças deixam nas folhas e as imagens foram coletadas e armazenadas na base de dados, separadas por características específicas das doenças.

Figura 8 - Exemplo de Imagens da Base



Fonte: Adaptada de (BEVERS, SIKORA, HARDY, 2022)

A base de dados contém 9.648 imagens originais e foi enriquecida com outras 1.074 imagens adicionais, obtidas tanto do banco de dados "Image Database of Plant Disease Symptoms (PDDB)" (BARBEDO *et al.*, 2016) quanto de recursos de extensão. Esses recursos incluem técnicas de processamento de imagens, como girar e espelhar fotos, para aumentar a diversidade e a representatividade dos dados.

A Tabela 1 exibe o número de imagens por categoria e o ano em que foram coletadas.

Tabela 1 - Número de Imagens por Classe

Categoria da Doença	Imagens originais 2020	Imagens originais 2021	Total	Imagens Adicionais Aumentadas	Imagens de Extensão	Total
mancha bacteriana	484	0	484	484	104	1072
queima das folhas por cercospora	1163	435	1598	0	38	1636
míldio	0	652	652	0	104	756
olho-de-rã causada pela Cercospora sojina	495	1045	1540	0	110	1650
Saudável	908	724	1632	0	31	1663
deficiência de potássio	0	1034	1034	0	49	1083
ferrugem da soja	1131	496	1627	0	127	1754
mancha-alvo	0	1081	1081	0	27	1108
TOTAL	4181	5467	9648	484	590	10722

Fonte: Adaptada e Traduzida de (BEVERS, SIKORA, HARDY, 2022)

Na Figura 9, observa-se o desequilíbrio na distribuição das amostras quando visto em porcentagem destacando-se a disparidade entre as amostras de queima por cercospora, totalizando 15% da base, e as de míldio, com apenas 7%.

Assim, é necessário o balanceamento de dados, sendo um processo fundamental no pré-processamento, que envolve equalizar a quantidade de amostras em cada classe, assegurando uma representação equitativa durante a análise (HAXIANG *et al.*, 2017).

Figura 9 - Distribuição das Amostras

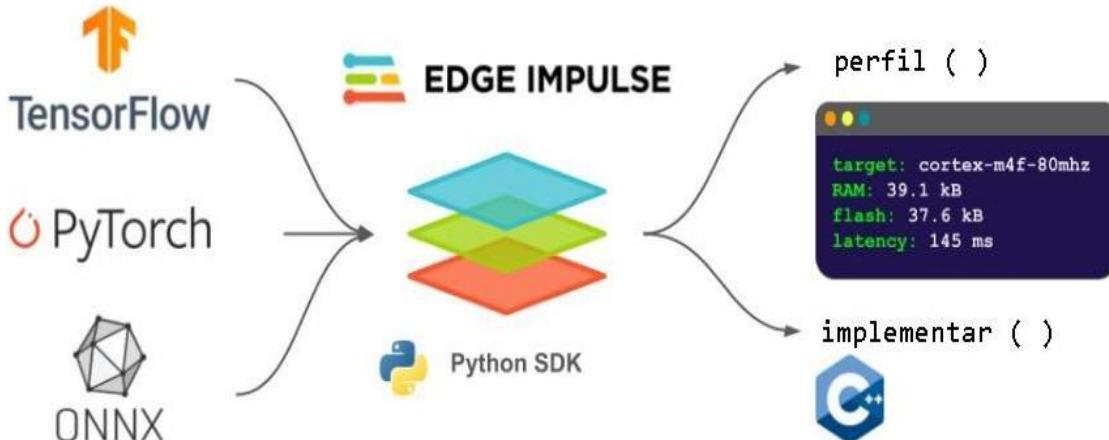


Fonte: Dos autores, (2024)

3.2. Desenvolvimento da rede neural com plataforma *no-code*

Visando realizar o desenvolvimento da rede neural utilizando plataforma *no-code* foi escolhido o Edge Impulse como ferramenta, na Figura 10 está sendo ilustrada as bibliotecas disponíveis.

Figura 10 - Esquema de Bibliotecas *Edge Impulse*



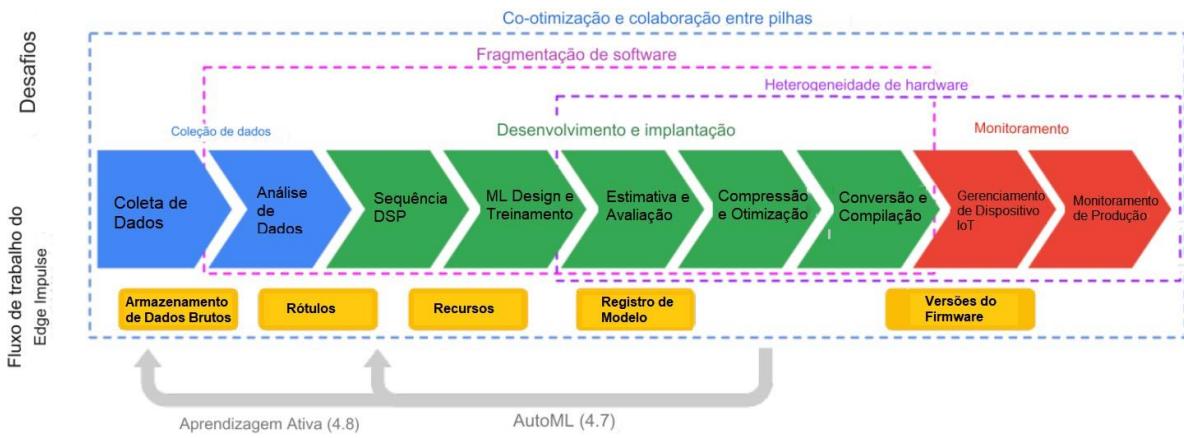
Fonte: Traduzido de (EDGE IMPULSE,2024)

O Edge Impulse oferece uma plataforma abrangente e poderosa que simplifica todo o processo de desenvolvimento de modelos de *machine learning* para aplicativos de IoT, desde a aquisição e preparação de dados até o treinamento, avaliação e implantação do modelo. Com interface intuitiva, bibliotecas de modelos pré-construídos e recursos avançados se torna acessível a uma ampla variedade de desenvolvedores e engenheiros (MIHIGO,2022).

Os projetos do Edge Impulse podem receber dados armazenados em vários formatos de arquivo, como CSV, CBOR, JSON, WAV, JPG ou PNG, com vários modos de coleta de dados, incluindo ferramentas de interface de linha de comando (CLI) que se comunicam com o firmware do dispositivo para ingestão de dados em tempo real e uma API baseada na web para fazer upload de dados diretamente ou de um armazenamento na nuvem existente (HYMEL, et al, 2022).

A Figura 11 apresenta o fluxo de trabalho de projetos no ambiente do Edge Impulse, simplificando a coleta, organização e treinamento de dados. Os usuários interagem com uma interface gráfica web e uma API. O Edge Impulse fornece uma biblioteca C/C++ portátil, incluindo otimizações para reduzir o tempo de inferência e o consumo de memória em diversos dispositivos-alvo (HYMEL, et al, 2022).

Figura 11 - Fluxo de trabalho do *Edge Impulse*



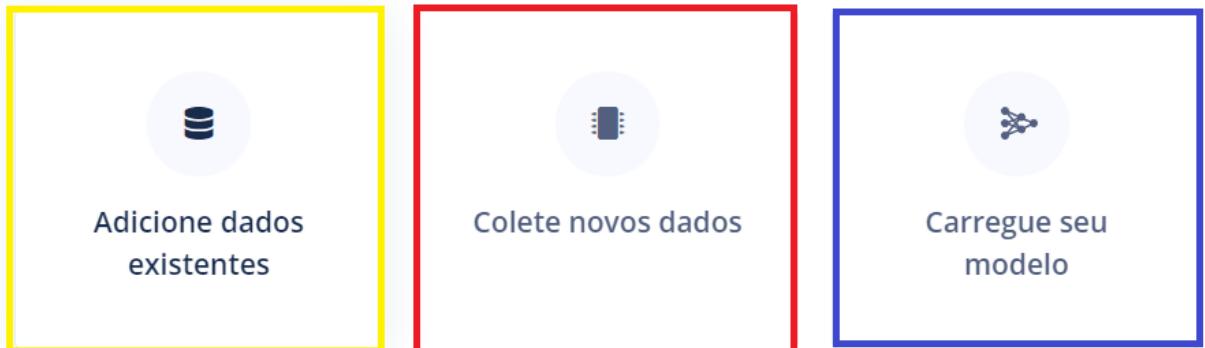
Fonte: Adaptado e Traduzido de (HYMEL, et al, 2022).

O processo de criação de um modelo de Rede Neural no Edge Impulse envolve diversas etapas após o usuário criar uma conta na plataforma, o que pode ser feito gratuitamente no site oficial (EDGE IMPULSE, 2024).

A Figura 12 apresenta a tela inicial do projeto, sendo que no bloco amarelo, é possível adicionar dados já existentes em uma pasta local; no bloco vermelho, adquirir dados dos sensores homologados para o ambiente Edge Impulse, como placas Arduino, Raspberry Pi ou dispositivos móveis; e no bloco azul, até adicionar um modelo já previamente treinado.

Figura 12 - Coleta de Dados

Comece a criar seu conjunto de dados ou valide o desempenho do seu modelo no dispositivo:



Comece com um tutorial

Não sabe por onde começar? Siga um tutorial para construir seu primeiro modelo em apenas alguns minutos!



Fonte: EDGE IMPULSE,2024

Logo após o *upload* das primeiras imagens ser realizado, a plataforma rapidamente já reconhece o tipo de detecção que será realizado e confirma em uma janela de *pop-up*, conforme Figura 13.

Figura 13 - Identificação do Tipo do Projeto

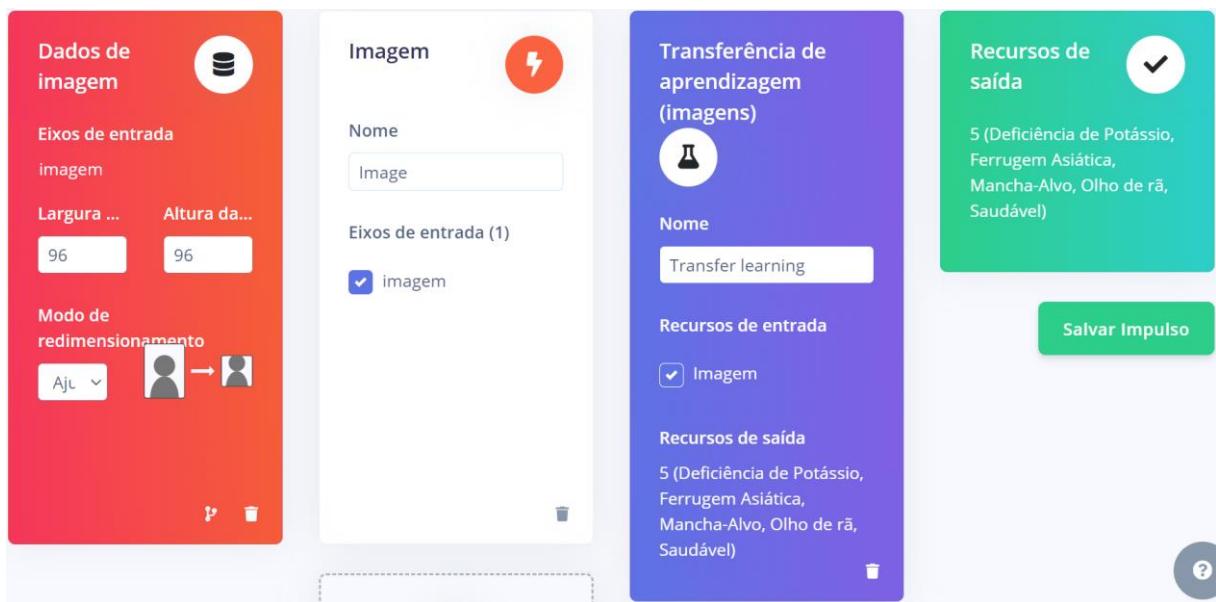


Fonte: Dos autores, (2024)

Com o tipo de detecção escolhido, o conjunto de dados é preparado e dividido entre imagens de treinamento e de teste, seguindo a proporção padrão de 80/20, podendo ser ajustada manualmente, dando maior flexibilidade para o projeto.

Posteriormente, a interface de "impulso de criação" vista na Figura 14 é acessada, permitindo a adição do impulso que irá analisar os dados fornecidos ao banco de imagens.

Figura 14 - Impulso de Criação



Fonte: Dos autores, (2024)

Em seguida, é hora de escolher o modelo de *machine learning* adequado. O Edge Impulse oferece diversos modelos pré-construídos, como CNNs e RNNs, e o

usuário pode selecionar o mais apropriado para o seu problema e inicia-se o treinamento do modelo. O Edge Impulse utiliza técnicas de aprendizado supervisionado, ajustando os parâmetros do modelo para minimizar a diferença entre as previsões e os rótulos reais dos dados.

Na Figura 15 foi demarcado por cores os parâmetros ajustáveis para o treinamento da rede e a seguir são explicados cada bloco.

Figura 15 - Rede Neural Configurações



Fonte: Dos autores, (2024)

O número de ciclos de treinamento (ou épocas) no bloco verde é um hiperparâmetro que pode ser ajustado durante o processo de treinamento do modelo. Ele

controla quantas vezes o conjunto de treinamento será apresentado ao modelo durante o treinamento. Um número maior de ciclos de treinamento pode permitir que o modelo aprenda mais com os dados de treinamento, mas também pode aumentar o risco de *overfitting* (sobreajuste) aos dados de treinamento.

A taxa de aprendizado no bloco amarelo controla o tamanho dos passos que o algoritmo de otimização dá ao ajustar os parâmetros do modelo durante o treinamento. Se a taxa de aprendizado for muito alta, pode levar a oscilações ou até mesmo a divergência no processo de otimização. Por outro lado, se for muito baixa, o treinamento pode ser lento e pode ficar preso em mínimos locais.

E por fim, no bloco vermelho o botão de escolher um modelo diferente permite que os usuários alternem rapidamente entre diferentes modelos disponíveis para ver como cada um se comporta em relação aos dados ou ao problema em questão. Isso pode ser útil para comparação de desempenho, busca por melhores resultados ou simplesmente para explorar diferentes abordagens de modelagem.

A Figura 16 mostra a aba implantação em vermelho, a interface de configuração do Edge Impulse onde o usuário pode escolher como implantar o modelo de aprendizado de máquina que foi treinado na plataforma.

Figura 16 - Implantação do Modelo



Fonte: Dos autores, (2024)

É possível implantar o modelo utilizando uma biblioteca C++ portátil, compatível com qualquer compilador C++ moderno, ou uma biblioteca específica para placas Arduino, que inclui exemplos de código para facilitar o uso. Outras opções incluem um modelo otimizado para o chip de inteligência artificial Akida da BrainChip, um pacote de software para microcontroladores STM32 que permite inferência rápida em diversos dispositivos, ou a criação de um bloco de implantação personalizado para atender a necessidades específicas do projeto.

3.3. *Tiny ml* com ia na borda

A necessidade de implementar modelos de aprendizado de máquina em sistemas embarcados é motivada pela exclusão de muitos dados sensoriais devido a restrições financeiras, falta de conectividade com a internet ou limitações de energia (SANCHEZ-IBORRA, SKARMETTA, 2020).

Uma solução para esse desafio é o *Tiny ML*. Ele implementa modelos de aprendizado de máquina (*machine learning* - ML) em dispositivos de baixa potência, como microcontroladores. Assim como a computação de borda, o *Tiny ML* tem como objetivo realizar inferências localmente nos dispositivos. Isso reduz a latência, economiza largura de banda e melhora a privacidade (DONG *et al*, 2021).

A integração entre a computação de borda e o *Tiny ML* visa trazer inteligência para a borda da rede. Permitindo processamento e tomada de decisão em tempo real, desde dispositivos IoT até automação industrial. Ao utilizar modelos *Tiny ML* na borda, os *frameworks* de computação podem melhorar suas capacidades para processamento, análise e resposta de dados (IODICE, 2022).

Além da computação de borda, outra abordagem importante é a computação em nuvem. Nela, os dados e processamentos são realizados em servidores remotos, em data centers, e acessados via internet (CAO,2020). No entanto, pode apresentar latência maior em comparação com a computação de borda, especialmente em cenários onde há necessidade de resposta rápida (VARGHESE *et al.*, 2016).

Para destacar as principais diferenças entre a computação de borda e a computação em nuvem, a Tabela 2 mostra uma comparação entre as duas abordagens em termos de latência, largura de banda, privacidade e outros aspectos relevantes

Tabela 2 - Diferenças entre Computação na Borda e na Nuvem

Aspecto	Computação de Borda	Computação em Nuvem
Latência	Baixa, pois processamento é local	Mais alta, devido à distância dos servidores remotos
Largura de Banda	Menor uso, devido à localidade	Potencialmente maior uso, devido à transmissão de dados pela rede
Privacidade	Melhor, pois dados permanecem locais	Dependente das políticas de segurança e privacidade do provedor de serviços em nuvem
Escalabilidade	Limitada, dependente dos recursos locais	Alta, devido à capacidade de expansão dos data centers
Disponibilidade	Dependente da conexão local	Dependente da disponibilidade e estabilidade dos serviços em nuvem
Custos	Potencialmente menores, devido ao uso eficiente de recursos locais	Variável, dependendo do modelo de cobrança e uso de recursos

Fonte: Adaptado de (CAO,2020).

3.4. Desenvolvimento do modelo

Para o desenvolvimento do primeiro modelo da Rede Neural para classificação de doenças de soja foram selecionadas 1.221 imagens sendo 969 para treinamento e 252 para teste. Já o segundo modelo de melhoria foram utilizadas 2.003 imagens, sendo 1.589 para treinamento e 414 para teste. Para o desenvolvimento dos modelos foram escolhidas imagens dentre as disponíveis na base de dados, as doenças que mais afetam a soja no Brasil atualmente (EMBRAPA, 2024). Dito isso as 5 classes para classificação foram: Soja Saudável;Olho de rã; Ferrugem Asiática, Mancha-Alvo e Deficiência de Potássio.

A Figura 17 apresenta a divisão das imagens para treinamento e teste de cada classe e o rótulo *label* definido para cada uma.

Figura 17 - Proporção de Treinamento / Teste

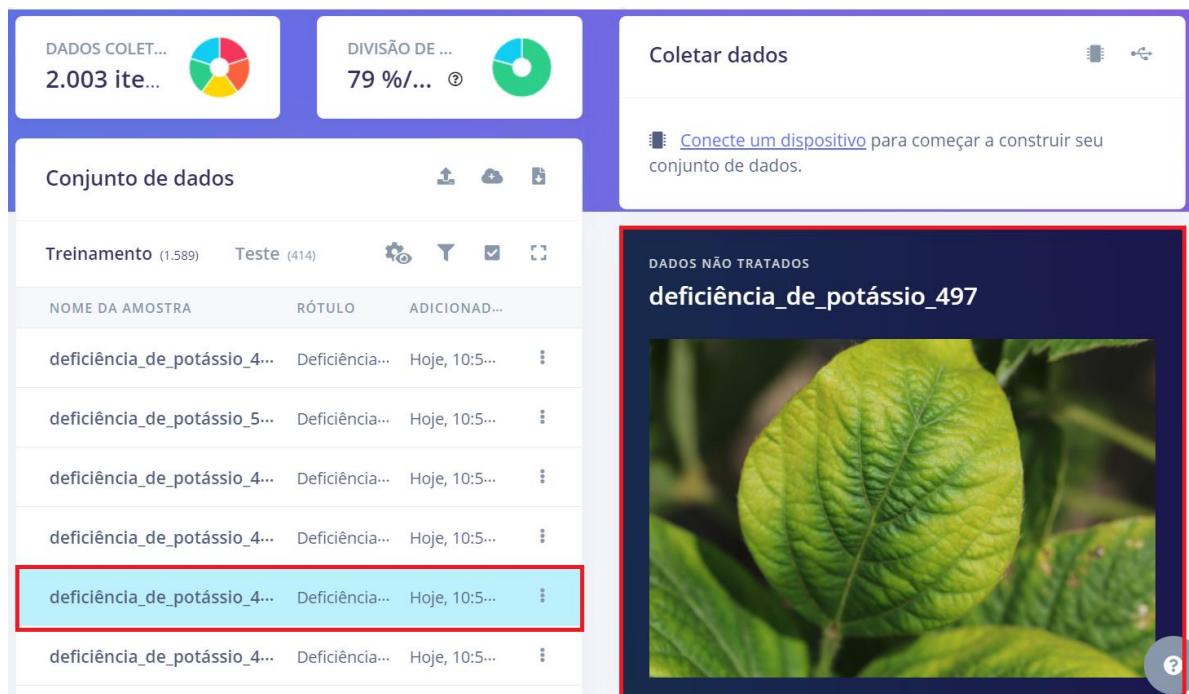
Os dados de treinamento são usados para treinar seu modelo, e **os dados de teste** são usados para testar a precisão do seu modelo após o treinamento. Recomendamos uma proporção aproximada de divisão de treinamento/teste de 80/20 para seus dados para cada classe (ou rótulo) em seu conjunto de dados, embora conjuntos de dados especialmente grandes possam exigir menos dados de teste.



Fonte: Dos autores, (2024).

A Figura 18 apresenta uma imagem da classe Deficiência de Potássio, com informações sobre a imagem (deficiência_de_potássio_497).

Figura 18 - Visualização Amostra Classe Olho de Rã

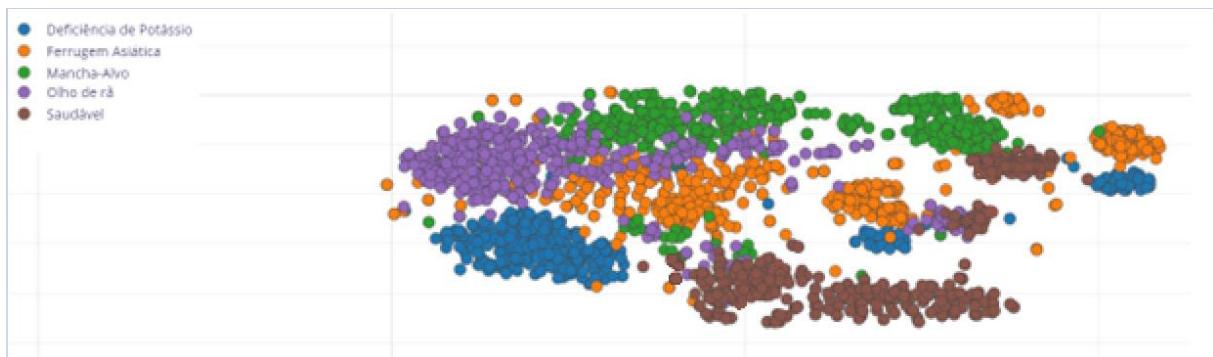


Fonte: Dos autores, (2024)

A Figura 19 apresenta o gráfico de dispersão das imagens selecionadas para o treinamento. Idealmente, em um gráfico de dispersão, as classes estariam nitidamente separadas, com seus dados agrupados de forma coesa. No entanto, no contexto das folhas de soja, devido a variações de tamanho, cor, iluminação e incidência da doença, alguns grupos de imagens acabam ficando mais dispersos dentro de suas classes.

Apesar dessas variações, é possível identificar padrões de agrupamento no gráfico. As folhas saudáveis tendem a agrupar-se na parte inferior, enquanto as afetadas pela doença Olho de Rã predominam no lado esquerdo. A deficiência de potássio é encontrada principalmente no canto inferior esquerdo, a ferrugem asiática concentra-se na parte centro-esquerda do gráfico, e a mancha-alvo se distribui na parte superior, delineando uma distribuição característica das classes.

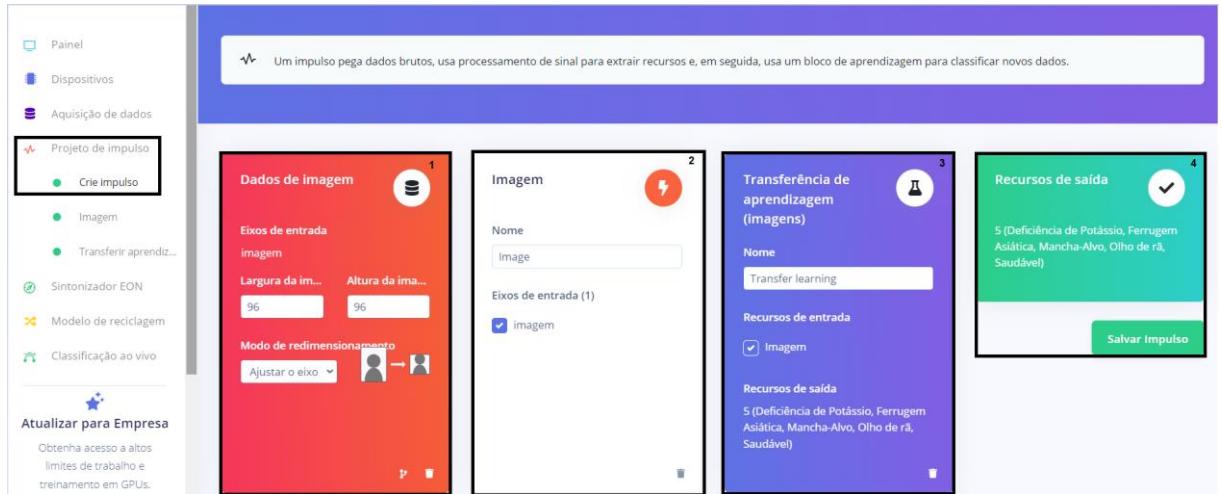
Figura 19 - Gráfico de Dispersão



Fonte: Dos autores, (2024)

A Figura 20 apresenta as etapas do desenvolvimento do Modelo de Rede Neural. No Bloco 1, os dados de entrada foram ajustados para o tamanho 96 x 96 pixels. No Bloco 2, foi especificado que os dados de entrada são imagens. O Bloco 3 utilizou a técnica de *Transfer Learning* para aproveitar modelos pré-treinados e acelerar o processo de treinamento. Finalmente, no Bloco 4, os recursos de saída foram definidos, com cinco categorias: Deficiência de Potássio, Ferrugem Asiática, Olho de Rã, Mancha-Alvo e Saudável, correspondendo aos rótulos das doenças nas imagens de entrada.

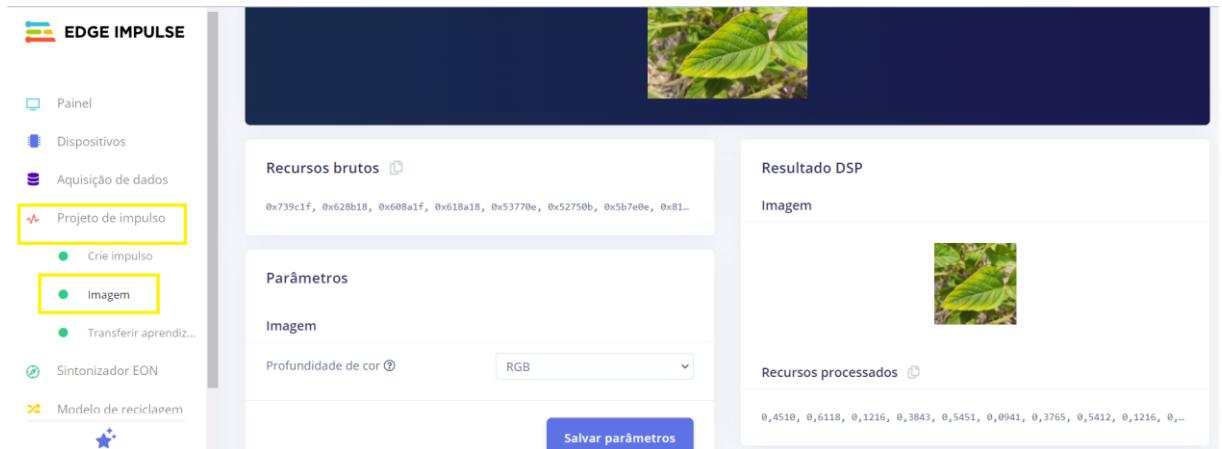
Figura 20 - Criação do Impulso



Fonte: Dos autores, (2024)

Na aba Imagem, como mostrado na Figura 21, optou-se por manter as imagens em escala RGB, pois muitas doenças apresentam características que envolvem a coloração das folhas, como por exemplo a Deficiência de Ferro, em que as folhas adquirem uma tonalidade amarelada, contrastando com o verde musgo das folhas saudáveis.

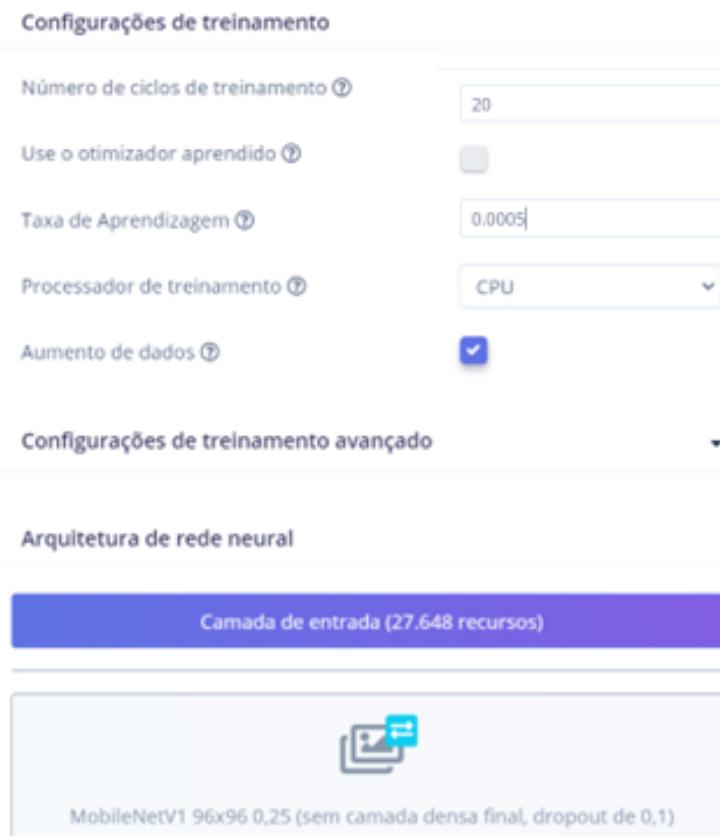
Figura 21 - Definição dos Parâmetros de cor da Imagem



Fonte: Dos autores, (2024)

Na final do pimeiro modelo, as configurações de treinamento mostrado na Figura 22, ajustou-se o número de ciclos de treinamento para 20 e a taxa de aprendizado para 0,0005, utilizando o modelo pré-treinado *MobileNetV2 96x96 0,35*.

Figura 22 - Configurações de Treinamento do Primeiro Modelo



Fonte: Dos autores, (2024)

Já para o segundo modelo foi testado diversos valores a fim de aumentar a acurácia final, com isso o conjunto de dados da Figura 23 apresentou o melhor dentre as limitações de trabalho, o número de ciclos de treinamento foi aumentada para 140 e juntamente com a taxa de aprendizado para 0,008, utilizando o mesmo modelo pré-treinado *MobileNetV2 96x96 0,25* que usa cerca de 105,9K RAM e 301,6K ROM com configurações e otimizações padrão.

Um maior número de ciclos de treinamento permite que a rede neural explore o espaço de soluções de forma mais abrangente, ajustando os parâmetros de forma mais precisa para minimizar o erro de classificação. A taxa de aprendizado mais alta acelera o processo de aprendizado, permitindo que a rede neural se aproxime da solução ideal com mais rapidez.

Figura 23 - Configurações de Treinamento do Segundo Modelo

The screenshot shows the 'Configurações de treinamento' (Training Configuration) section of a software interface. It includes the following settings:

- Número de ciclos de treinamento (Number of training cycles): 140
- Use o otimizador aprendido (Use learned optimizer):
- Taxa de Aprendizagem (Learning rate): 0.008
- Processador de treinamento (Training processor): CPU
- Aumento de dados (Data augmentation):

Below this, under 'Configurações de treinamento avançado' (Advanced Training Configuration), there is a section titled 'Arquitetura de rede neural' (Neural network architecture). It highlights the 'Camada de entrada (27.648 recursos)' (Input layer (27.648 resources)) in blue. This layer is described as 'MobileNetV1 96x96 0,25 (sem camada densa final, dropout de 0,1)' (MobileNetV1 96x96 0,25 (without final dense layer, dropout 0,1)).

Fonte: Dos Autores, (2024)

Para facilitar a integração do modelo com *hardware*, optou-se pela implantação como Biblioteca Arduino vista na Figura 24. Essa escolha permite utilizar o modelo em conjunto com os códigos de *hardware* da IDE do Arduino, proporcionando maior flexibilidade ao projeto e a possibilidade de adicionar funcionalidades personalizadas.

Figura 24 - Biblioteca para Arduino

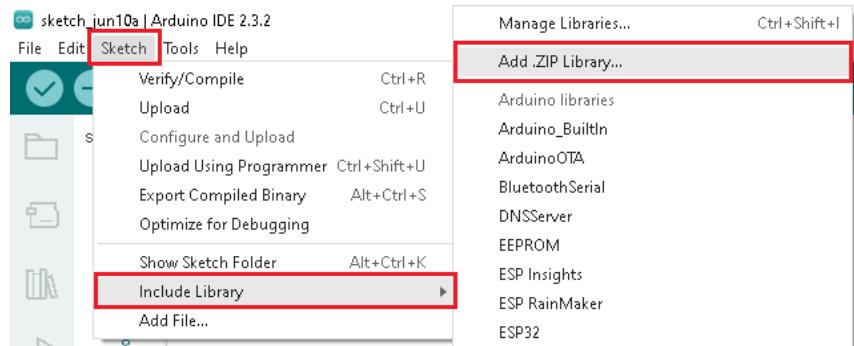


Fonte: Dos Autores, (2024)

A biblioteca, exportada para a Arduino IDE, permite a implementação offline e a personalização do sistema pelo usuário. Ao utilizar a biblioteca de classificação na Arduino IDE, podemos integrar elementos como GPS, *display* e bateria, proporcionando portabilidade e informações adicionais para o controle do usuário. No *software*, diversas bibliotecas são essenciais para o funcionamento harmonioso dos equipamentos, e as peculiaridades de cada dispositivo complementam o projeto.

A biblioteca gerada pelo Edge Impulse vem em formato compactado, normalmente salvo na extensão (.ZIP). Para adicionar esse tipo de biblioteca para o Arduino IDE, basta abrir a plataforma de desenvolvimento e clicar em Rascunho ou *Sketch*, na parte superior esquerda da tela. Na sequência, necessita-se clicar em Incluir Biblioteca *Include Library* e Adicionar Biblioteca .ZIP *Add .ZIP Library*, conforme a Figura 25.

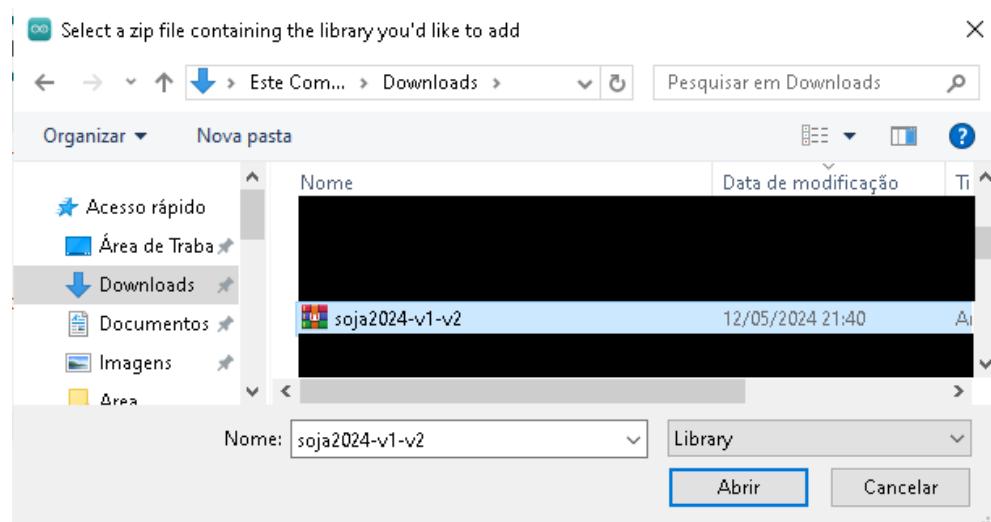
Figura 25 - Adicionando Biblioteca ao Arduino IDE



Fonte: Dos Autores, (2024)

Na sequência, é necessário escolher o arquivo correto, baixado do Edge Impulse e, na sequência, clicar em Abrir, conforme a Figura 26.

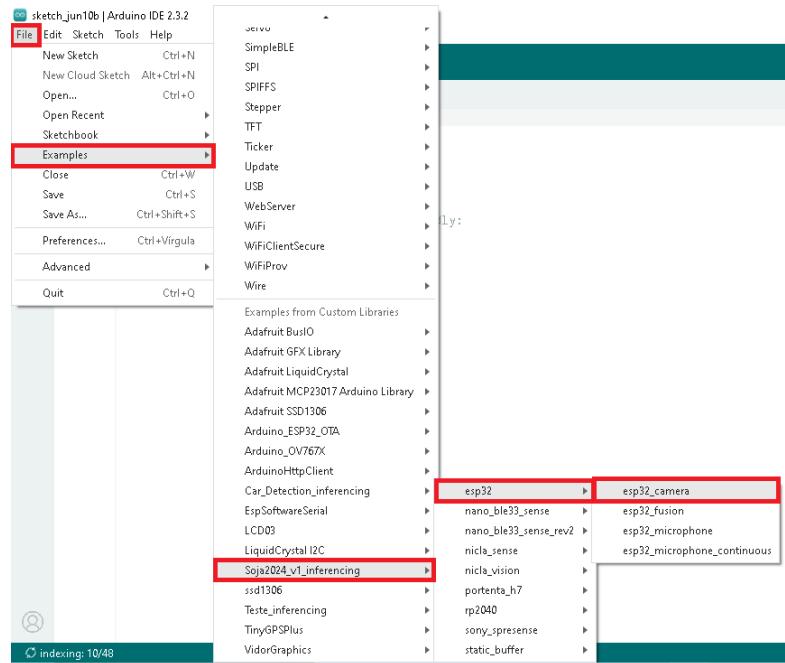
Figura 26 - Escolhendo Biblioteca no Arduino IDE



Fonte: Dos Autores, (2024)

Após a instalação das bibliotecas, os exemplos práticos que as acompanham podem ser explorados. Estes exemplos, acessíveis em "Arquivo" ou "File" > "Exemplos" ou "Examples", apresentados na Figura 27, demonstram as funcionalidades das bibliotecas e servem como ponto de partida para o aprendizado de sua utilização. A partir da análise e compreensão dos exemplos, torna-se possível desenvolver projetos próprios com maior autonomia e conhecimento.

Figura 27 - Exemplos da Biblioteca Arduino IDE



Fonte: Dos Autores, (2024)

Na Figura 28, há a representação do novo rascunho que é aberto pela plataforma, trazendo o código de exemplo inteiro dentro dele.

Figura 28 - Exemplo Arduino IDE

The screenshot shows the Arduino IDE code editor with the file "esp32_camera.ino" open. The code is as follows:

```

1  #include <Soja2024_v1_inferencing.h>
2  #include "edge-impulse-sdk/dsp/image/image.hpp"
3
4  #include "esp_camera.h"
5
6  // Select camera model - find more camera models in camera_pins.h file here
7  // https://github.com/espressif/arduino-esp32/blob/master/libraries/ESP32/examples/Camera/CameraWebServer/camera\_pins.h
8
9  //#define CAMERA_MODEL_ESP_EYE // Has PSRAM
10 #define CAMERA_MODEL_AI_THINKER // Has PSRAM
11
12 #if defined(CAMERA_MODEL_ESP_EYE)
13 #define PWDN_GPIO_NUM    -1
14 #define RESET_GPIO_NUM   -1
15 #define XCLK_GPIO_NUM     4
16 #define SIO0_GPIO_NUM     18
17 #define SIOC_GPIO_NUM     23
18
19
20 #define Y9_GPIO_NUM       36
21 #define Y8_GPIO_NUM       37
22 #define Y7_GPIO_NUM       38
23 #define Y6_GPIO_NUM       39
24 #define Y5_GPIO_NUM       35
25 #define Y4_GPIO_NUM       14
26 #define Y3_GPIO_NUM       13
27 #define Y2_GPIO_NUM       34
28 #define VSYNC_GPIO_NUM    5
29 #define HREF_GPIO_NUM     27
30 #define PCLK_GPIO_NUM     25
31

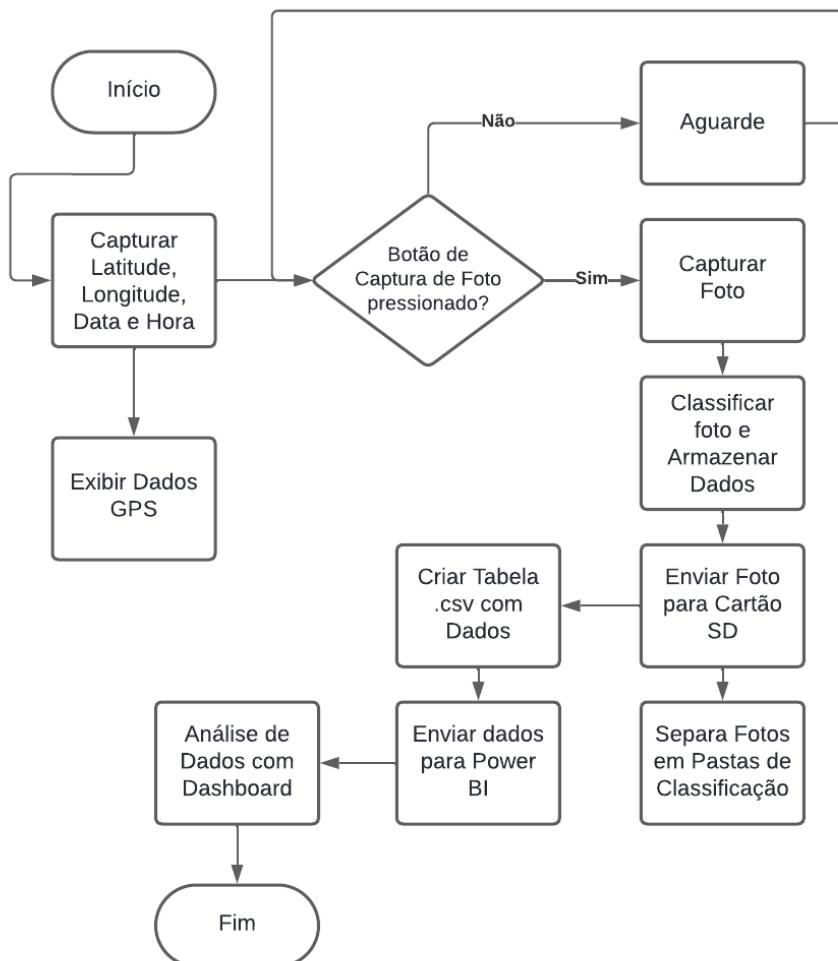
```

Fonte: Dos Autores, (2024)

Modelos de exemplo de rascunho são comumente utilizados como ponto base dos códigos desenvolvidos, por já possuírem uma base funcional que possa ser implementada. O código fonte completo desenvolvido para este trabalho encontra-se no Apêndice II. A listagem detalhada permite uma análise mais aprofundada da implementação e das soluções adotadas para os desafios técnicos enfrentados.

No fluxograma representado na Figura 29, pode-se observar como ocorre o funcionamento da aplicação. Onde o GPS e *display* trabalham o tempo inteiro, esperando o comando do botão de capturar fotos ser pressionado para darem sequência. A representação mostra o funcionamento de todos os passos do processo até chegar o momento de analisar os dados obtidos pela aplicação.

Figura 29 - Fluxograma de Funcionamento



Fonte: Dos Autores, (2024).

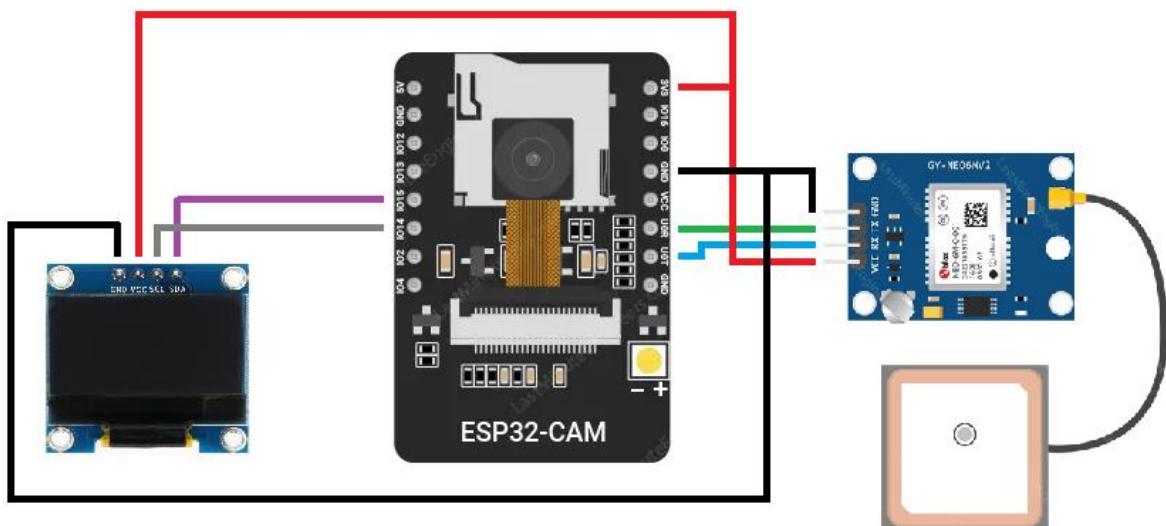
3.5. Desenvolvimento do *hardware* do protótipo

Nesta seção são apresentados o diagrama de blocos, o circuito eletrônico e a montagem física do protótipo.

3.5.1 Diagrama de blocos do protótipo

Para utilizar um ESP-CAM32 com um GPS GY NEO6M.V2, é recomendado utilizar as portas lógicas GPIO 14 e GPIO15 para fornecerem uma comunicação eficiente, onde a transmissão do GPS é recebida pelo primeiro, enquanto o sinal é enviado pelo segundo. Para disponibilizar informações sobre a localização geográfica, tais como longitude e latitude, utiliza-se um *display* OLED .96" 128x64 LCD, conforme a Figura 30.

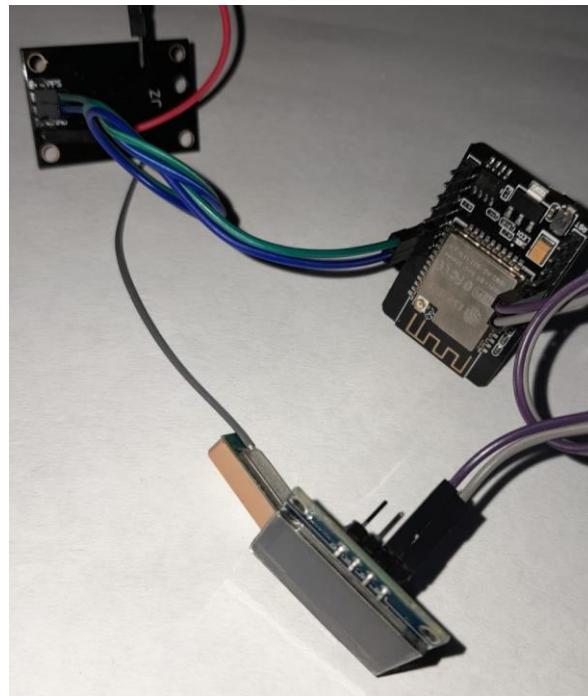
Figura 30 - Diagrama de Blocos das Conexões Básicas ESP32-CAM com GPS e display



Fonte: Dos Autores, (2024).

Contudo, o ESP32-CAM também possibilita a utilização dos pinos *GPIO* 1 (UOTXD, transmissor da placa) e *GPIO* 3 (UORXD, receptor da placa) para conexões de transmissão e recepção de dados, respectivamente. A fim de ter uma disposição confortável entre os componentes, optou-se por utilizar o GPS nos *GPIOs* 1 e 3, e o display nos *GPIOs* 14 e 15. A Figura 31 ilustra as conexões implementadas no protótipo, onde os fios azul e verde estabelecem a comunicação entre o GPS e o ESP32-CAM, enquanto os cabos cinza e roxo transmitem dados da placa de desenvolvimento para o display, seguindo o padrão de cores da Figura 30.

Figura 31 - Protótipo das Conexões Básicas dos Componentes



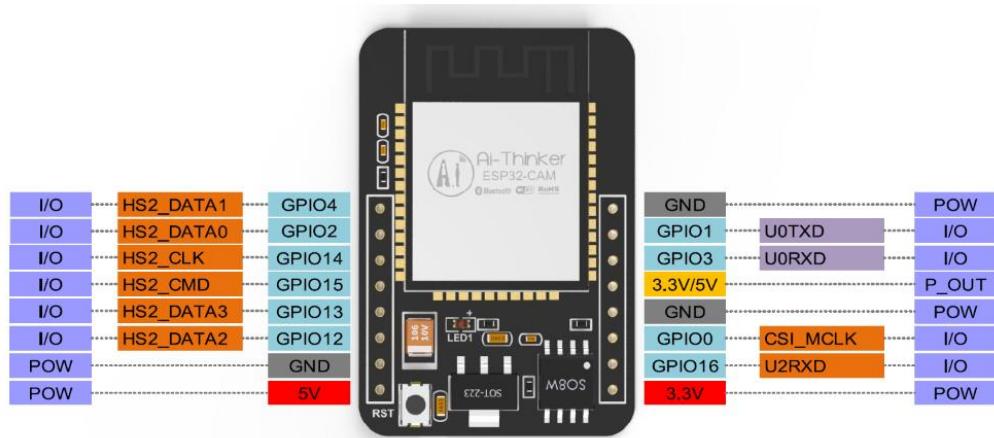
Fonte: Dos Autores, (2024).

3.5.2 Descrição do módulo esp32 – cam

Para o projeto do *hardware* foi selecionado o ESP32 CAM, por possuir integrado um microcontrolador ESP32 S, com 4M de memória PSRAM, câmera OV2640 de 2MP, interface para cartão microSD, comunicação Wi-Fi com antena integrada e pinos GPIO disponíveis para conexão de outros dispositivos.

O desenvolvimento do *software* e a gravação no ESP 32 CAM pode ser feita utilizando o ambiente da IDE do Arduino. A Figura 32 mostra a pinagem do ESP32 CAM.

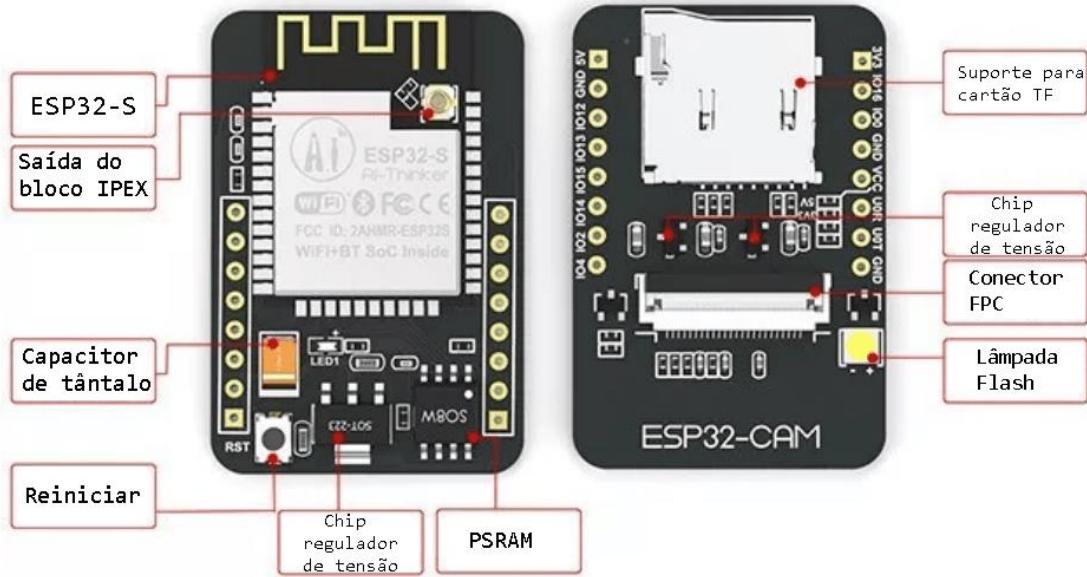
Figura 32 - Pinagem do módulo ESP32 CAM



Fonte: AI-THINKER, 2024

A Figura 33 apresenta o módulo ESP32 CAM com as duas faces, e com isso pode-se visualizar a interface do cartão micros.

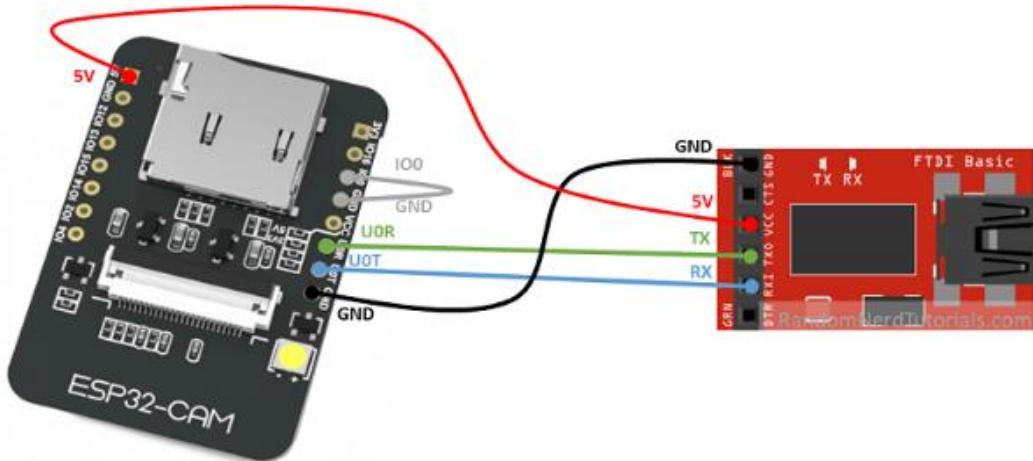
Figura 33 - Apresentação das duas faces da placa do ESP32 CAM



Fonte: AI-THINKER, 2024

O processo de gravação do código na placa ESP32 CAM pode ser realizado utilizando uma interface serial USB-TTL com o adaptador mostrado na Figura 34, ou ainda com o uso de um módulo próprio para gravação, mostrado na Figura 35, onde se observa a câmera incluída no *hardware*.

Figura 34 - Módulo de gravação com interface serial USB-TTL



Fonte: Randon Nerds Tutorials, 2024

Figura 35 - Módulo auxiliar para a gravação do ESP32 - CAM



Fonte: Randon Nerds Tutorials, 2024

A Tabela 3 apresenta as especificações técnicas do módulo ESP32 CAM

Tabela 3 - Especificações do Módulo ESP32 CAM

Especificações do Módulo ESP32 CAM	
Modelo	ESP32 CAM
Montagem	Encapsulamento DIP-16 pinos
Tamanho	27 x 40,5 mm
SPI Flash	Padrão de 32 Mbit
Memória RAM	520 KB SRAM + 4M PSRAM
Bluetooth	Bluetooth 4.2 BR/EDR e padrão BLE
Wi-Fi	802.11 b/g/n
Interfaces	UART, SPI, I2C, PWM
Suporte Micro SD card	Supporte até 4 G
Portas de E/S	9

Especificações do Módulo ESP32 CAM	
Velocidade <i>Baudrate</i>	Padrão de 115200 bps
Formato de saída da imagem	JPEG, BMP, GRayscale
Faixa de frequência	2412 ~ 2484 MHz
Antena	Onboard com ganho de 2dBi
Potência de transmissão	802.11b: 17 +/- 2 dBm (@11 Mbps) 802.11g: 14 +/- 2 dBm (@54 Mbps) 802.11n: 13 +/- 2 dBm (@MCS7)
Sensibilidade de Recepção	CCK, 1 Mbps: - 90dBm CCK, 11 Mbps: - 85dBm 6 Mbps (1/2 BSPK): - 88 dBm 54 Mbps (3/4 64-QAM): -70dBm MCS7 (65 Mbps, 72.2 Mbps): -67dBm
Dissipação de Potência	Desligar <i>flash</i> da lâmpada: 180mA @ 5V Ligar <i>flash</i> da lâmpada no brilho máximo: 310 mA @ 5 V Deep-Sleep (“dormindo”): consumo de 6 mA @ 5 V

Fonte: AI-THINKER, 2024

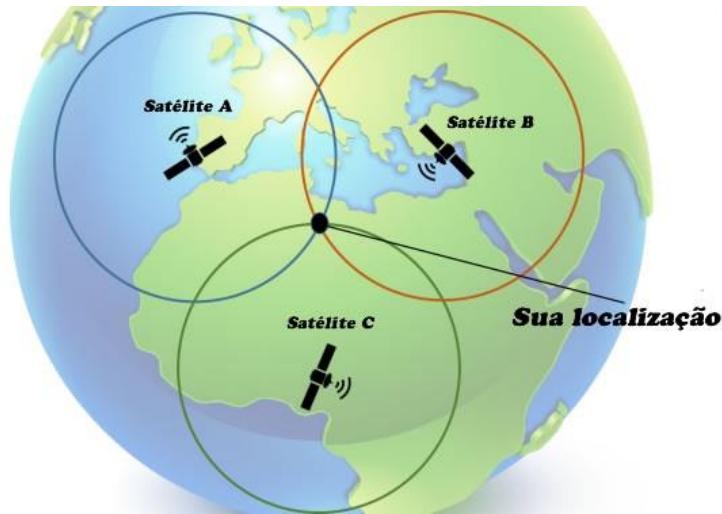
3.5.3 Descrição da conexão gps utilizada no protótipo

A função dos receptores GPS é descobrir a que distância estão de vários satélites, que transmitem informações sobre sua posição e a hora atual na forma de sinais de rádio em direção à Terra.

A Terra possui milhares de satélites orbitando ao redor dela, incluindo satélites de comunicação que são identificados por sistemas de GPS e informam ao receptor onde eles estão localizados. O receptor calcula a distância de cada satélite, considerando quanto tempo levou para os sinais chegarem, e com a triangulação (informações sobre a distância de pelo menos três satélites e onde eles estão no espaço), o receptor pode identificar sua localização na Terra.

O receptor estima a latitude, longitude e altitude com base nas informações recebidas dos satélites. Quanto mais satélites estiverem visíveis para o receptor e quanto melhor for a precisão das medições temporais, mais precisa será a determinação da posição pelo GPS. A Figura 36 mostra como funciona a triangulação.

Figura 36 - Triangulação a Partir de Satélites

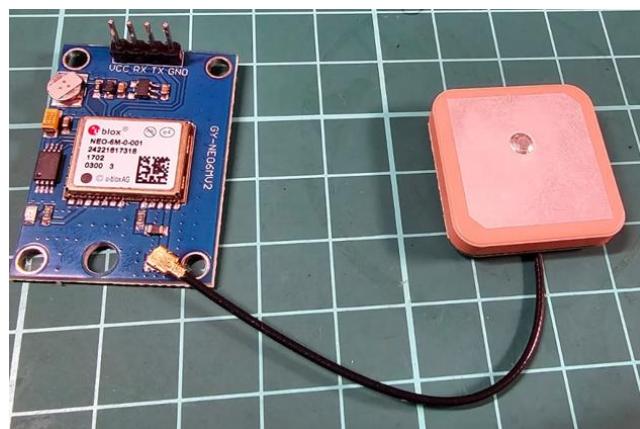


Fonte: Adaptado de Só Física, 2024.

O módulo utilizando no protótipo, mostrado na Figura 37, foi o GPS GY-NEO6MV2 que possui uma antena externa para melhorar a recepção do sinal e a comunicação com o sistema de microcontrolador é feita via serial RX/TX. A Tabela apresenta as especificações técnicas.

A tensão de operação do chip NEO-6M varia de 2,7V a 3,6V. Ele conta com um regulador integrado de 3,3V no módulo, permitindo que os pinos lógicos recebam tensão de 5V. Essa característica simplifica a conexão com placas Arduino ou microcontroladores que operam em nível lógico de 5V, eliminando a necessidade de reguladores de tensão externos. As especificações técnicas do módulo GPS estão listadas na Tabela 4.

Figura 37 - Módulo GPS GY NEO6MV2



Fonte: Dos autores, 2024

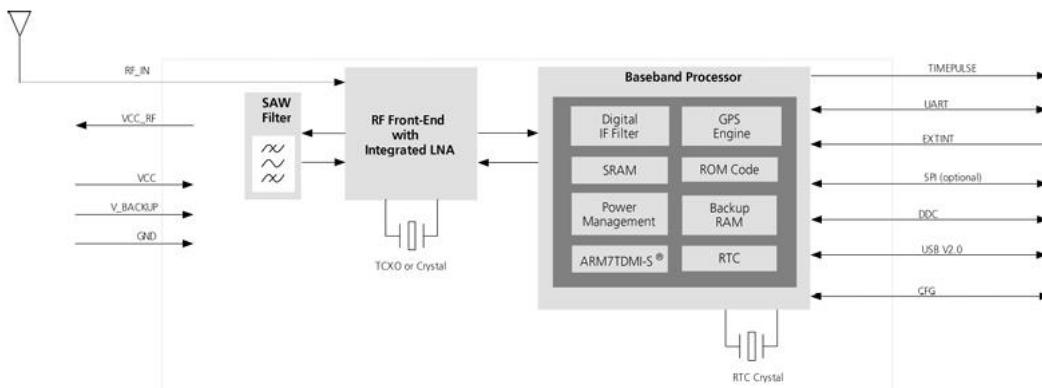
Tabela 4 - Especificações Técnicas do Módulo GPS GYNEO6MV2

Modelo	GY- NEO6MV2
Tensão de operação	2,7 a 3,6 VDC
Corrente de operação	45 mA
Comunicação	Serial RX/TX
Conector	Modelo U. FL para antena
Nível lógico	3,3 e 5 V
Taxa de comunicação (padrão)	9600 bauds
Warm start	1 s
Cold start	27 s
Temperatura de operação	-40 a 85° C
Precisão	2,5 m

Fonte: GY-NEO6MV2, 2024

A arquitetura interna do módulo GY-NEO6MV2 é mostrada na Figura 38.

Figura 38 - Arquitetura interna do módulo GY-NEO6MV2



Fonte: GY-NEO6MV2, 2024

O módulo GY-NEO6MV2 pode rastrear até 22 satélites em 50 canais, com uma sensibilidade de rastreamento de -162dBm e consome apenas 45mA de corrente, com até 5 atualizações de localização por segundo com precisão de posição horizontal de 2,5m.

Um recurso importante para projetos é o modo *Power Save Mode* (PSM), que permite uma redução no consumo de energia do sistema ligando e desligando seletivamente partes do receptor, e que reduz o consumo de energia do módulo de 45 para 11mA, adequado para aplicações sensíveis à energia, como por exemplo, relógio de pulso com GPS.

O Módulo GPS GY-NEO6MV2 possui uma EEPROM de 4KB conectada ao chip NEO-6M, uma bateria recarregável que atua como um super capacitor e que podem

armazenar os dados de relógio e posição mais recentes, assim, o tempo de detecção de dados é reduzido sempre que iniciar o módulo.

3.5.4 Descrição do Lcd *display oled .96" 128x64*

O *display OLED* (*Organic Light-Emitting Diode*) de 0.96 polegadas, com resolução de 128x64 pixels, é um componente essencial para a visualização de informações no protótipo. Ele se destaca por sua alta qualidade de imagem, baixo consumo de energia e design compacto. A Figura 39 mostra dimensionamentos e pinagem do LCD OLED .96". Onde SCL é o pino responsável por gerar o 'Clock', enquanto o SDA é o encarregado pelos dados.

Figura 39 - Pinagem e Dimensionamento OLED .96"



Fonte: Adaptado de Robô Marte, 2024.

O *display OLED* opera com uma interface I2C, facilitando a comunicação com o microcontrolador ESP32. Ele possui um controlador SSD1306 integrado, responsável por gerenciar a exibição de dados na tela. As especificações técnicas do LCD *DISPLAY OLED .96" 128x64* estão na Tabela 5, ele oferece um alto contraste e amplo ângulo de visão, garantindo a legibilidade das informações em diferentes condições de iluminação.

Tabela 5 - Descrição Técnica do Oled .96"

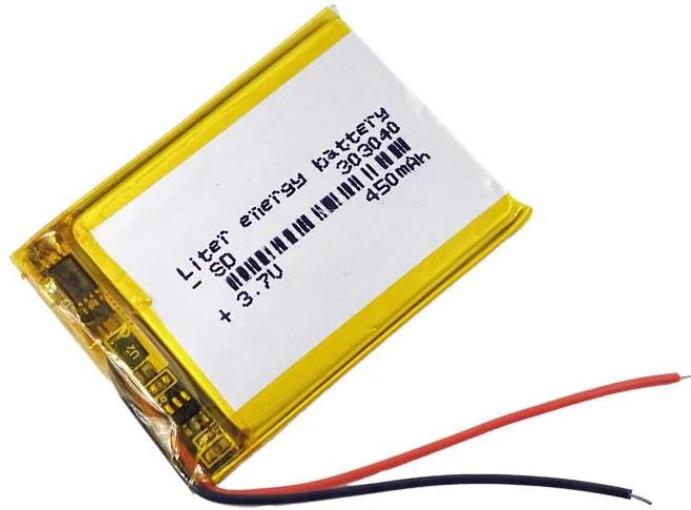
CARACTERÍSTICAS	VALOR
Tecnologia	OLED
Tamanho da Tela	0.96 polegadas
Resolução	128 x 64 pixels
Interface	I2C
Controlador	SSD1306
Tensão de Alimentação	3.3V
Cor de Exibição	Monocromático (geralmente branco ou azul)
Ângulo de Visão	>160°
Temperatura de Operação	-40°C a 80°C
Dimensões do Módulo (LxAxP)	27.0 x 27.0 x 4.1 mm (aproximadamente)
Peso	7.0g (aproximadamente)

Fonte: Adaptado de Winstar Display, 2023.

3.5.5 Alimentação do Protótipo

Para alimentar o protótipo e garantir sua portabilidade em campo, optou-se pela utilização de uma bateria de lítio modelo *Liter Energy Battery SD 303040*, com tensão de 3.7V e capacidade de 450mAh. Essa bateria oferece um bom equilíbrio entre tamanho compacto, peso leve e capacidade energética suficiente para alimentar os componentes eletrônicos do sistema por um período adequado para a coleta de dados. Ademais, a utilização de uma bateria recarregável contribui para a sustentabilidade do projeto, reduzindo o consumo de baterias descartáveis e o impacto ambiental. A Figura 40 demonstra a bateria utilizada.

Figura 40 - Bateria de Lítio



Fonte: Dos Autores, 2024.

A Tabela 6 mostra características da bateria selecionada para a alimentação do protótipo.

Tabela 6 - Características Bateria Recarregável

CARACTERÍSTICA	VALOR
Modelo	SD 303040
Química	Lítio
Tensão Nominal	3.7V
Capacidade Nominal	450mAh
Dimensões (mm)	30 x 30 x 4.0
Peso (g)	8.5
Temperatura de Operação	-20°C a 60°C

Fonte: Adaptado de Liter Energy Battery, 2024.

3.5.6 Montagem eletrônica do protótipo

A montagem eletrônica do protótipo visa a integração eficiente dos componentes para garantir a captura, classificação e registro de dados de folhas de soja. O ESP32-CAM, com sua câmera integrada, é o elemento central, capturando imagens e comunicando-se com o módulo GPS Ublox NEO-6M via serial para obter

dados de localização. O *display* OLED 0.96", conectado via I2C ao ESP32-CAM, oferece *feedback* visual ao usuário, exibindo informações relevantes como *status* e coordenadas.

O protótipo será alimentado por uma bateria externa, proporcionando portabilidade e autonomia para operação em campo. A escolha da bateria dependerá do consumo de energia dos componentes e da duração desejada para a coleta de dados, para esse modelo, será utilizada uma bateria de 3,7V. A conexão da bateria ao sistema será realizada através dos pinos de alimentação positivo e negativo da bateria SD303040, que foram divididos em três cabos para sinal positivo e três cabos para sinal negativo, conforme a Figura 41, garantindo o fornecimento de energia estável para todos os módulos.

Figura 41 - Figura Bateria SD303040 Com Seus Terminais Divididos



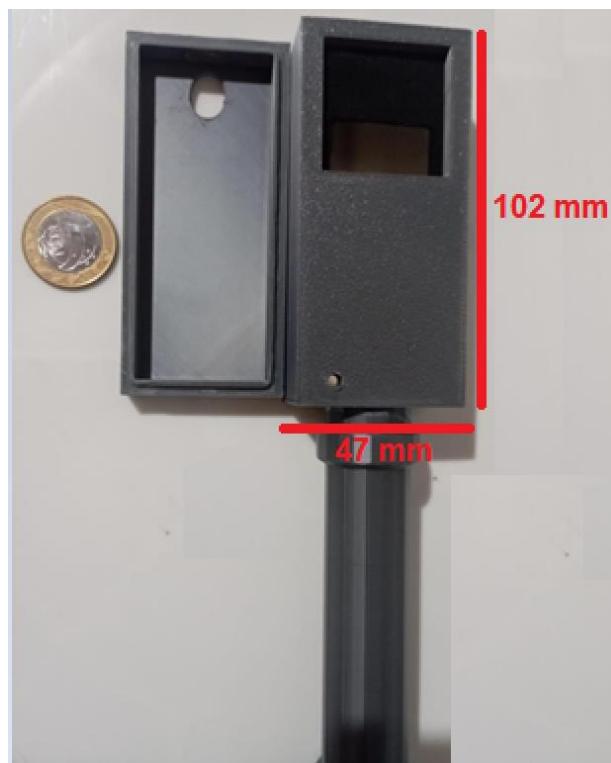
Fonte: Dos Autores, 2024.

Com o intuito de assegurar a portabilidade e a salvaguarda do protótipo durante a coleta de dados em ambiente externo, foi engendrado um receptáculo sob medida por meio da manufatura aditiva (impressão tridimensional). Este receptáculo, também denominado invólucro ou manopla, foi concebido para acomodar o ESP32-CAM, o visor OLED, o módulo GPS, a bateria e os demais componentes eletrônicos de maneira segura e organizada.

A impressão em 3 dimensões (3D) propicia a flexibilidade necessária para a criação de um design sob medida, levando em consideração as dimensões precisas dos componentes e a necessidade de acesso aos botões e conectores. O invólucro foi arquitetado com aberturas estratégicas para a lente da câmera, o visor e a antena do GPS, garantindo o funcionamento ideal do sistema. Ademais, o material empregado na impressão tridimensional confere resistência e durabilidade, protegendo os componentes eletrônicos contra impactos, poeira e umidade.

A utilização da manufatura aditiva para a produção do invólucro possibilitou a prototipagem célere e a realização de ajustes no design de forma ágil e economicamente viável. O resultado é uma manopla personalizada, funcional e esteticamente aprazível, que contribui para a praticidade e a eficiência do protótipo durante a coleta de dados em campo. A tampa do invólucro apresenta dimensões de 102 mm de comprimento, 47 mm de largura e 10 mm de altura. A base, por sua vez, possui as mesmas medidas de comprimento e largura, porém com 28 mm de altura. A Figura 42 ilustra a versão final do invólucro em comparação com uma moeda de um real, oferecendo uma referência visual de seu tamanho.

Figura 42 - Case do Dispositivo Desenvolvido



Fonte: Dos Autores, (2024).

3.6. Interface de análise de dados

O *Power BI* é uma ferramenta de análise de dados desenvolvida pela (MICROSOFT, 2024), com recursos de inteligência do negócio (*business intelligence -BI*), e capacidade de criar visualizações interativas e relatórios dinâmicos a partir de conjuntos de dados diversos. Amplamente utilizada em diversos setores, sua popularidade se deve à sua facilidade de uso e integração com uma variedade de fontes de dados, incluindo bancos de dados, arquivos locais, serviços na nuvem e aplicativos da web.

No decorrer do projeto, o *Power BI* foi utilizado para analisar os dados provenientes das coletas de imagens efetuadas na fazenda. Na página inicial, destacada na Figura 43, estão presentes dois botões interativos que conduzem a outras seções do relatório. Ao clicar no botão "*Dashboard*", os usuários são direcionados para a análise dos dados coletados na fazenda, enquanto o botão "*Cartilhas*" os encaminha para uma tela dedicada à apresentação de informações específicas sobre cada doença identificada.

Figura 43 - Tela Inicial *Power BI*

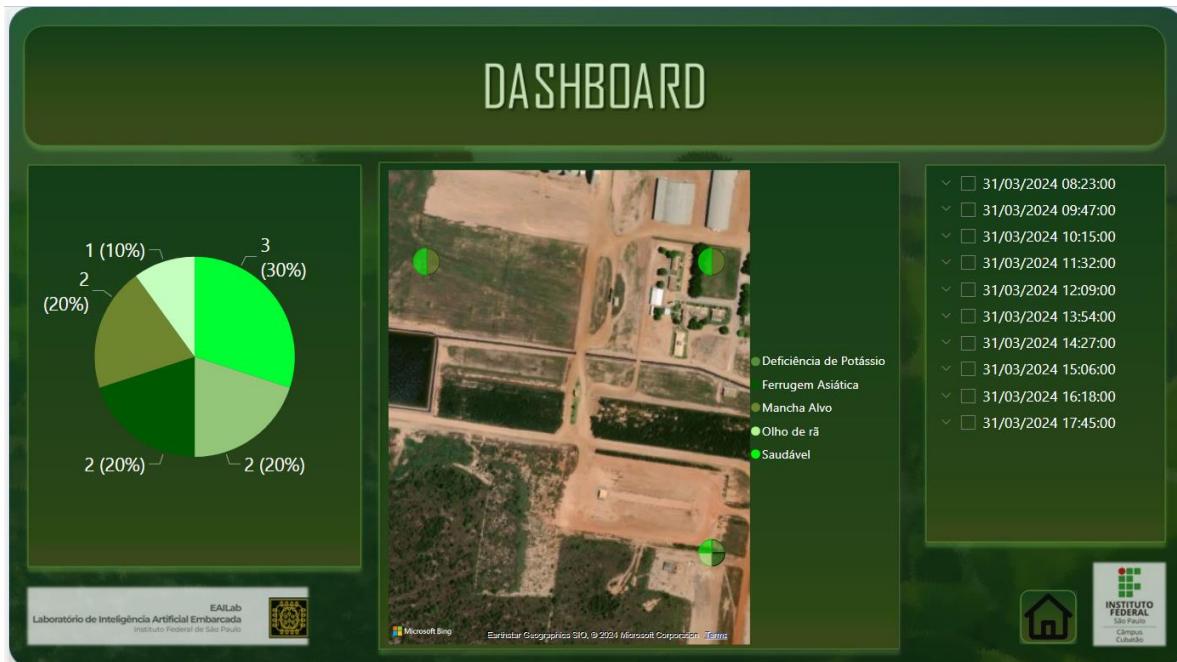


Fonte: Dos Autores, (2024)

No *Dashboard* ilustrado na Figura 44, foram integrados elementos visuais para representar os dados de forma dinâmica. Ao clicar no botão correspondente, os

usuários são redirecionados para esta página, onde encontram uma representação visual dos dados coletados.

Figura 44 - Dashboard para Análise dos Dados



Fonte: Dos Autores, (2024)

Esses elementos incluem um mapa que recebe as coordenadas das imagens capturadas na fazenda. Essa visualização geoespacial dos dados possibilita uma análise detalhada das regiões da fazenda onde ocorrem problemas, proporcionando uma compreensão visual das áreas afetadas.

Adicionalmente, um gráfico de pizza foi incorporado para apresentar a distribuição percentual de cada doença identificada nas imagens, bem como a porcentagem de plantas consideradas saudáveis. Essa representação simplificada facilita a compreensão da distribuição das diferentes condições das plantas na fazenda.

Outro componente relevante é uma tabela que exibe o dia e o horário de cada coleta de imagem. Essa informação temporal é fundamental para o acompanhamento da evolução das análises ao longo do tempo, permitindo a identificação de padrões ou tendências. É importante ressaltar que os dados mostrados são exemplos fictícios, utilizados apenas para ilustrar a forma visual de apresentação das informações.

Voltando à tela inicial e acessando o botão "Cartilhas", conforme mostrado na Figura 45, é possível selecionar dados sobre as quatro doenças que a rede é capaz de detectar.

Figura 45 - Cartilhas sobre as doenças de soja



Fonte: Dos Autores, (2024)

Ao clicar em "mancha alvo", os usuários são redirecionados para uma nova tela, como ilustrado na Figura 46. Nesta tela, são apresentadas as condições favoráveis para o aparecimento da doença, os sintomas e as medidas de controle.

Figura 46 - Cartilha doença Mancha Alvo



Fonte: Dos Autores, (2024)

Além disso, há um botão no canto inferior esquerdo que leva a um link do (AGROLINK, 2024), onde é possível encontrar mais detalhes sobre os sintomas e danos causados pela doença na plantação, bem como uma lista de mais de 100 produtos recomendados para o manejo da doença. Essa lista inclui o nome técnico dos produtos, a empresa fabricante, a composição e toda a classificação técnica, conforme mostrado um exemplo de produto indicado na Figura 47.

Figura 47 - Produto Abacus HC para Mancha Alvo

AGROLINKFITO

PRODUTOS **CONTEÚDOS TÉCNICOS** **PESQUISAS** **NOTÍCIAS**

Abacus HC

GERAL

Nome Técnico: Piraclostrobina; Epoxiconazol	Registro MAPA: 9210	Empresa Registrante: Basf
--	------------------------	------------------------------

COMPOSIÇÃO

Ingrediente Ativo	Concentração
Piraclostrobina	260 g/L
Epoxiconazol	160 g/L

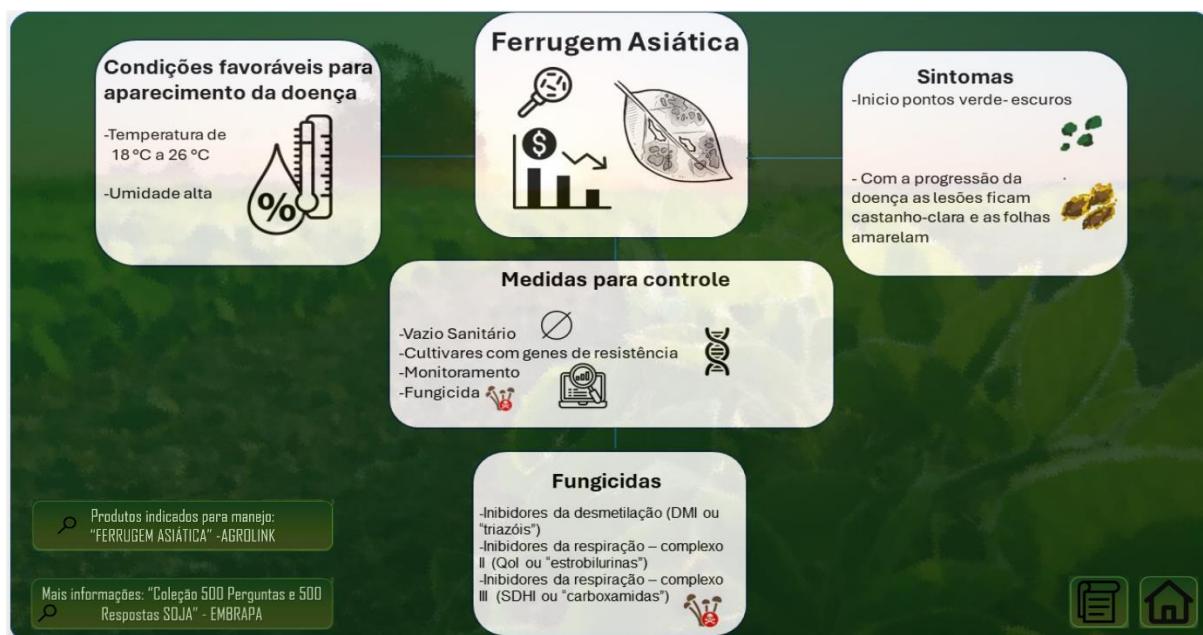
CLASSIFICAÇÃO

Técnica de Aplicação: Terrestre/Aérea	Classe Agronômica: Fungicida	Toxicológica: 4 - Produto Pouco Tóxico
Ambiental: II - Produto muito perigoso	Inflamabilidade: Não inflamável	Corrosividade: Não corrosivo
Formulação: Suspensão Concentrada (SC)	Modo de Ação: Sistêmico	

Fonte: Agrolink, (2024)

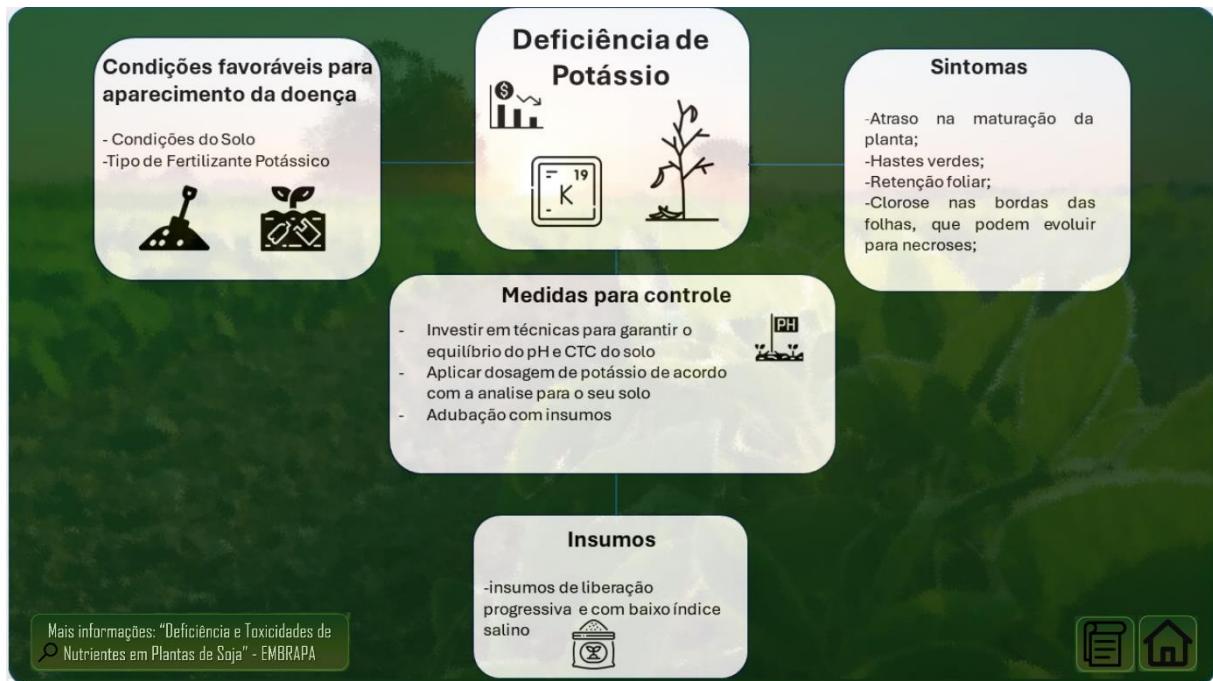
Seguindo o mesmo padrão as Figuras 48, 49 e 50 mostram as cartilhas das outras doenças e seus respectivos links de acesso.

Figura 48 - Cartilha Ferrugem Asiática



Fonte: Dos Autores, (2024)

Figura 49 - Cartilha Deficiência de Potássio



Fonte: Dos Autores, (2024)

Figura 50 - Cartilha Olho de Rã



Fonte: Dos Autores, (2024)

3.7. Relatório para análise geral das amostras

Visando complementar as informações fornecidas pelo *Dashboard* de BI e auxiliar no manejo eficiente de doenças foliares na lavoura, foi desenvolvido um relatório de análise geral das amostras como uma ferramenta de apoio ao agricultor visto na Figura 51. Enquanto o *Dashboard* oferece uma visão detalhada da incidência de doenças por localização geográfica, este relatório se concentra na doença com maior incidência identificada na coleta de imagens, fornecendo um guia prático para as ações iniciais a serem tomadas.

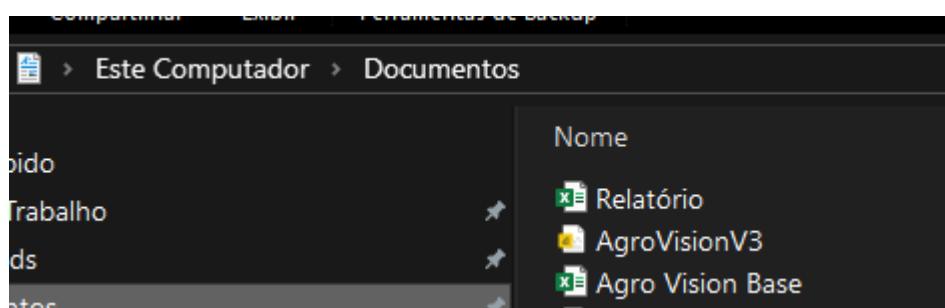
Figura 51 - Relatório para análise geral

RELATÓRIO DE ANÁLISE GERAL DAS AMOSTRAS	
	DE ATÉ
COLETA DE IMAGENS	09/06/2024 09/06/2024
	INCIDÊNCIA
SAUDÁVEL	3
DEFICIÊNCIA DE POTÁSSIO	2
MANCHA ALVO	4
OLHO DE RÃ	1
FERRUGEM ASIÁTICA	7
TOTAL DE AMOSTRAS	17
A doença que mais apresentou incidência na coleta feita foi a Ferrugem Asiática	
*Monitorar a lavoura semanalmente, principalmente em períodos de alta umidade e temperaturas amenas (15-28°C), para identificar os primeiros sintomas da doença. * Iniciar a aplicação de fungicida específico para ferrugem asiática o mais rápido possível, seguindo as recomendações do agrônomo. *Após o período de tratamento refazer a inferência para identificar se a planta está saudável.	
AÇÕES REALIZADAS () Consulta com agrônomo _____ () Aplicação de fungicida _____ () Manejo da irrigação _____ () Adubação (tipo e dose) _____ () Controle de plantas daninhas _____	
Práticas de MID Implementadas: () Rotação de Culturas () Escolha de Cultivares Resistentes () Tratamento de Sementes () Monitoramento Regular da Lavoura	
Responsável pela Avaliação: Assinatura do Agricultor/Técnico:	

Fonte: Dos Autores, (2024)

Este relatório foi projetado para ser alimentado pela base de dados vinda do cartão SD, que contém informações detalhadas sobre as análises realizadas. Para garantir a atualização precisa dos dados, é crucial que ambos os arquivos, o relatório e a base de dados, estejam armazenados na mesma pasta como vista na Figura 52 que ambas estão em Documentos.

Figura 52- Armazenamento dos Arquivos



Fonte: Dos Autores, (2024)

A atualização dos dados no relatório é realizada através de uma planilha interna, vinculada à base de dados por meio da funcionalidade "Obter Dados" do Excel. Essa vinculação permite que as informações da base de dados sejam importadas diretamente para o relatório, garantindo a consistência e a precisão dos dados.

Para atualizar os dados do relatório, o usuário deve primeiramente abrir o arquivo e certificar-se de que tanto o relatório quanto a base de dados estejam abertos e salvos na mesma pasta. Em seguida, identificar a tabela “Base de Dados” em vermelho na Figura 53. Na guia de Dados do Excel deve-se selecionar a opção “Atualizar” em azul na Figura 53. Ao realizar essa ação, o Excel buscará os dados atualizados da base de dados e atualizará automaticamente a tabela no relatório já apresentando o relatório personalizado para aquele grupo de imagens.

Figura 53- Atualização do Dados

The screenshot shows a Microsoft Excel interface with the following details:

- Top Bar:** Shows 'Salvamento Automático' (Automatic Save) as off, and tabs for Arquivo, Página Inicial, Inserir, Layout da Página, Fórmulas, Dados, Revisão, Exibir, Automatizar, and Ajuda.
- Dados Tab:** Selected tab.
- Obter e Transformar Dados Group:** Contains buttons for 'Obter' (Get), 'De Text/CSV', 'Da Imagem', 'Fontes Recentes', 'De Tabela/Intervalo', 'Conexões Existentes', 'Atualizar Tudo' (highlighted with a blue box), 'Consultas e Conexões', 'Propriedades', 'Links', and 'Organização'.
- Table:** A data table with columns labeled 'lat', 'long', 'data/hora', 'Resultado', 'Column5', 'Column6', 'Column7', and 'Column8'. Rows 1 through 35 show data points, mostly 'saudavel' with some 'picture' values.
- Bottom Navigation:** Shows 'Relatório' and 'Base de Dados' (highlighted with a red box).

Fonte: Dos Autores, (2024)

Através de um diagnóstico simplificado, o relatório apresenta a doença com maior incidência, facilitando a identificação do problema em campo. Em seguida, oferece um guia de ação personalizado, com instruções sobre os próximos passos a serem tomados para o manejo da doença.

Para auxiliar no controle e acompanhamento do tratamento, o relatório inclui um *checklist* de ações, abrangendo desde a consulta ao agrônomo até o manejo da

irrigação. Além disso, apresenta um *checklist* para acompanhamento das práticas de Manejo Integrado de Doenças.

A fim de garantir a responsabilidade e a continuidade do manejo da doença, o relatório disponibiliza campos para identificação do responsável pela avaliação e assinatura. A formatação do relatório foi feita para possibilitar a impressão deste relatório para uso em campo durante as inspeções da lavoura, registrando as ações realizadas e planejando os próximos passos. A atualização constante do relatório permite manter um histórico completo do manejo da doença, facilitando a consulta e o acompanhamento da evolução do tratamento.

Este relatório não substitui, mas sim complementa o *Dashboard* de BI, oferecendo informações mais detalhadas e direcionadas para a ação. A utilização conjunta de ambas as ferramentas permite ao agricultor tomar decisões mais assertivas e eficazes no manejo das doenças foliares, contribuindo para uma safra mais saudável e produtiva.

3.8. Questionário sobre manejo de doenças e práticas culturais

O vazio sanitário, período em que a semeadura da soja é proibida em determinadas regiões do país, visa reduzir a quantidade de inóculo de doenças na entressafra, como a ferrugem asiática (MAPA, 2023). Essa medida fitossanitária, apesar de essencial para o controle de doenças, impôs desafios à pesquisa, impedindo a realização de testes de campo durante o período de desenvolvimento deste trabalho.

Em São Paulo, o vazio sanitário da soja, período de 90 dias em que o cultivo é proibido, é regulamentado pela Resolução SAA nº 59, de 11 de setembro de 2021. Para a safra 2024/2025, o vazio sanitário foi regionalizado e, em algumas regiões do estado, teve seu início adiantado para 1º de junho de 2024 (CDA, 2024).

Diante da limitação imposta pelo vazio sanitário e buscando estabelecer contato direto com profissionais envolvidos no dia a dia da cultura da soja, visando não apenas coletar informações relevantes, mas também divulgar o trabalho desenvolvido e abrir portas para futuras parcerias, foi elaborado um questionário online utilizando a plataforma Google Forms. Essa ferramenta versátil possibilitou a

criação de um questionário estruturado, com perguntas de diferentes formatos (fechadas, abertas e de múltipla escolha), otimizando a coleta de dados de forma eficiente e organizada.

O questionário foi aplicado a quatro proprietários de fazendas de soja, onde três estão localizadas no estado de Mato Grosso e um em Tocantins. As perguntas abordaram desde o perfil do agricultor, suas práticas de cultivo e o uso de tecnologias, até os desafios enfrentados no dia a dia, visando coletar informações relevantes para o desenvolvimento de soluções mais eficazes, como o sistema proposto neste trabalho. O questionário completo encontra-se no Apêndice A.

4. RESULTADOS OBTIDOS

Nesse capítulo é exibido os resultados obtidos da rede treinada, seu desempenho e acurácia com as diferentes classes de doenças.

4.1. Acurácia alcançada pelo modelo da rede neural

Após o treinamento da Rede Neural, a acurácia inicial obtida foi de 71,1% com perda de 2,18, esse valor indica o desempenho durante o treinamento ou seja, valores menos equivale a um melhor desempenho. Já no segundo treinamento com uma base maior e parâmetros diferentes foi obtida uma acurácia de 87,7%, com perda de 0,36.

Ao analisar a matriz de confusão do modelo com acurácia de 71,1%, mostrado na Figura 54, observa-se em vermelho mais escuro que em 51,2% das vezes em que imagens rotuladas como "Olho de Rã" foram apresentadas à rede, estas foram erroneamente classificadas como "Ferrugem Asiática". Esse erro indica uma confusão recorrente entre essas duas classes e necessidade de melhoria no desempenho.

Figura 54 - Matriz de confusão primeiro modelo



Fonte: Dos Autores, (2024)

Ao analisar a segunda matriz de confusão apresentada na Figura 55, observa-se que a maioria das classes possui uma porcentagem de erro inferior a 5%. No entanto, as classes com maiores erros são: Ferrugem Asiática, com 8,2% das imagens erroneamente classificadas como Deficiência de Potássio, e Olho de Rã, com 11,3% das imagens classificadas como Deficiência de Potássio.

Figura 55 - Matriz de confusão

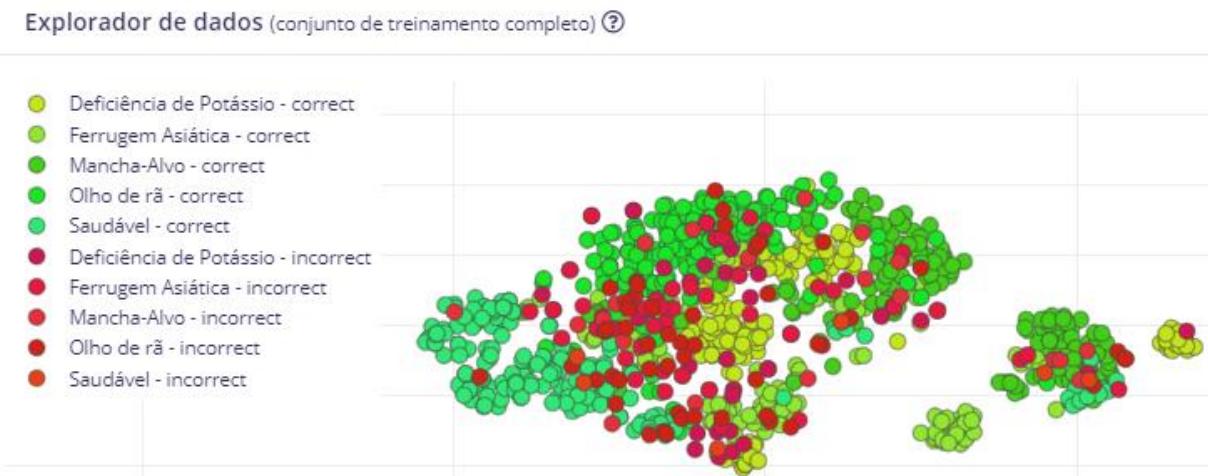


Fonte: Dos Autores, (2024)

A matriz de confusão do primeiro modelo revelou um erro frequente na classificação de "Olho de Rã" como "Ferrugem Asiática" em 51,2% dos casos, que não foi um problema para o segundo modelo já que o aumento dos ciclos e da taxa de aprendizado possibilitou à rede neural aprender com esses erros e reduzir a taxa de classificação incorreta.

Para uma análise mais detalhada do modelo final, é possível examinar as amostras onde ocorreram classificações erradas. O gráfico de dispersão de resposta mostrado na Figura 56 destaca em verde os itens classificados corretamente, enquanto os itens em vermelho indicam classificações incorretas. Essa diferenciação permite uma avaliação mais precisa das áreas em que o modelo precisa ser aprimorado.

Figura 56 - Gráfico de Dispersão dos Resultados



Fonte: Dos Autores, (2024)

Ao selecionar uma das imagens classificadas de forma incorreta, podem ser analisadas algumas características da imagem e com isso compreender o motivo pelo qual a rede neural apresentou erro na classificação.

A Figura 57 apresentada uma amostra de uma folha classificada como "Olho de Rã", mas erroneamente identificada como "Deficiência de Potássio". Esse equívoco pode ter sido causado pela coloração amarelada e presença de manchas na folha.

No entanto, é importante notar que o amarelado da folha era resultado do processo natural de envelhecimento, enquanto as manchas eram de fato características da doença Olho de Rã. Essa análise revela a necessidade de aprimorar a rede neural para minimizar a influência de características como idade da folha e condições de iluminação do ambiente nos resultados.

Figura 57 - Amostra com classificação errada



Fonte: Dos Autores, (2024)

4.2. Analise das respostas do questionário

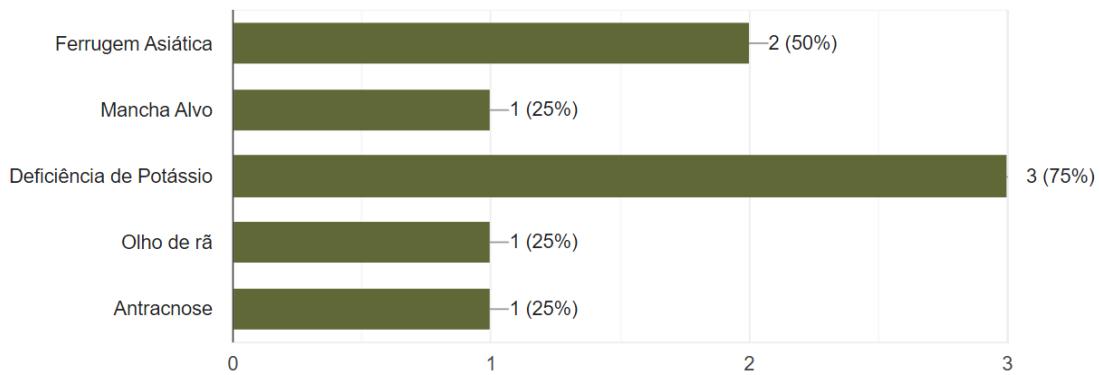
A análise das respostas do questionário inicia-se pela caracterização dos participantes em relação ao tempo de experiência com a cultura da soja e aos métodos de cultivo utilizados.

Dos quatro agricultores entrevistados, dois possuem menos de 5 anos de experiência com a cultura da soja, um possui de 5 a 10 anos e outro possui mais de 20 anos. A Figura 58 ilustra as doenças que eles consideram as maiores ameaças para o cultivo de soja.

Figura 58 - Resposta retirada do questionário sobre as doenças e região

Quais doenças que afetam a folha de soja são mais comuns na sua região?

4 respostas



Fonte: Dos Autores, (2024)

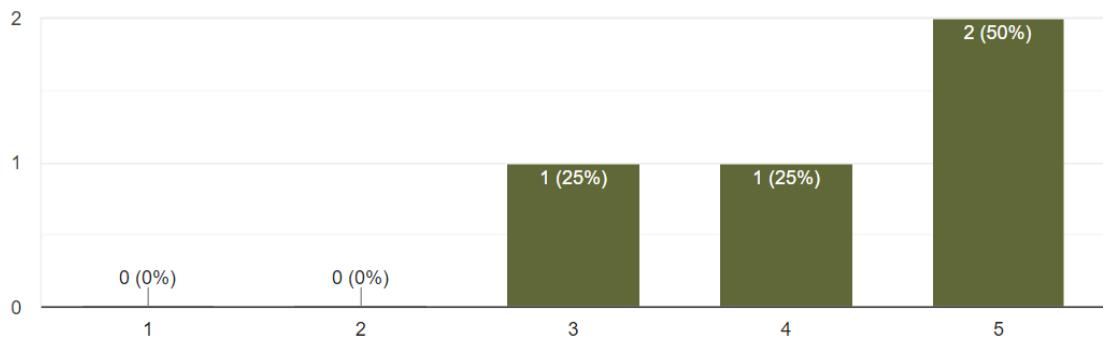
Todas as doenças propostas para detecção no presente trabalho foram citadas pelos agricultores, com destaque para a deficiência de potássio, mencionada por 3 dos 4 participantes e a ferrugem asiática, citada por 2. Além disso, um dos agricultores mencionou a antracnose, uma doença não incluída no escopo atual do trabalho, o que pode servir como ponto de partida para pesquisas futuras e possível inclusão na base de treinamento da rede neural.

Os resultados da Figura 59 indicam que as doenças causam um impacto financeiro considerável na produção de soja. Já que o menor nível foi 3 em uma escala de 1 a 5, onde 1 é menor impacto e maior impacto, o que sugere que as doenças podem gerar perdas significativas de produtividade e custos adicionais elevados com tratamento. Essa informação destaca a importância do desenvolvimento de estratégias eficazes de manejo e controle de doenças na cultura da soja.

Figura 59 - Impacto Financeiro

Qual é o impacto financeiro das doenças na sua plantação de soja em termos de perdas de produtividade e custos adicionais de tratamento?

4 respostas



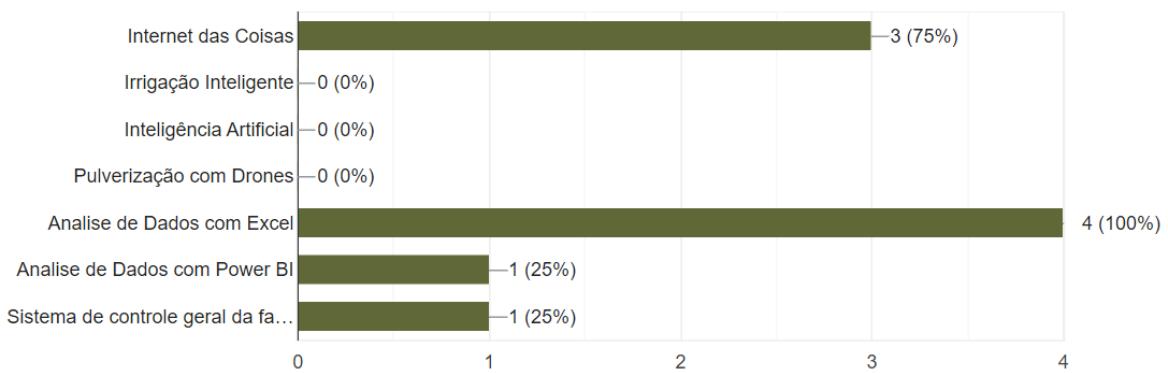
Fonte: Dos Autores, (2024)

Os resultados da Figura 60 mostram que a análise de dados com Excel se destaca como uma ferramenta universalmente utilizada, possivelmente devido à sua acessibilidade e facilidade de uso. A alta adoção da IoT sugere que os agricultores estão buscando soluções para conectar e monitorar seus equipamentos e processos agrícolas.

Figura 60 - Tecnologias Aplicadas

Quais das seguintes tecnologias foram implementadas em sua fazenda?

4 respostas



Fonte: Dos Autores, (2024)

Por outro lado, tecnologias mais avançadas, como Inteligência Artificial e Pulverização com Drones, ainda não foram incorporadas por nenhum dos

entrevistados. Isso pode ser devido a fatores como alto custo, falta de conhecimento ou receio em relação à adoção de novas tecnologias por isso trabalhos como esse são fundamentais para difundir e desmitificar o uso de IA.

4.3. Resultado final da montagem

Após a análise individual dos componentes, a presente seção se dedica à integração e avaliação do desempenho do dispositivo como um todo. A Figura 61 ilustra o resultado da montagem, revelando um equipamento compacto e ergonômico, projetado para facilitar o manuseio e a coleta de dados em campo.

Figura 61 - Resultado da Montagem



Fonte: Dos Autores, (2024)

A manopla impressa em 3D, além de abrigar os componentes eletrônicos, proporciona uma interface tátil agradável e garante a proteção contra impactos e intempéries. As aberturas estratégicas para a lente da câmera e o *display* permitem o

funcionamento ideal do sistema, enquanto a bateria externa oferece a autonomia necessária para a operação contínua em campo.

4.4. Testes de desempenho

Para avaliar a acurácia do sistema após sua integração, foi realizado um teste prático utilizando 54 folhas de soja dispostas sobre uma mesa. As quantidades de folhas por classe variavam, porém, a classificação real e correta de cada uma era conhecida. As imagens utilizadas no teste foram extraídas da mesma base de dados (BEVERS, SIKORA, HARDY, 2022) empregada no treinamento do modelo, mas com amostras distintas para evitar resultados falso-positivos e garantir uma avaliação mais precisa do desempenho em condições reais. A matriz de confusão gerada a partir deste teste será fundamental para analisar a performance do sistema, revelando sua capacidade de classificar corretamente as folhas de soja e identificar possíveis erros.

Na Figura 62 está o dispositivo sendo apontado para as folhas para captura das imagens.

Figura 62 - Teste do Modelo



Fonte: Dos Autores, 2024.

Com as imagens capturadas e armazenadas, o cartão de memória é retirado da parte traseira do dispositivo como visto na Figura 63 para ser inserido no computador.

Figura 63 - Cartão de Memória



Fonte: Dos Autores, (2024)

Com o cartão já no computador, ao abri-lo observa-se na Figura 64 as pastas de cada uma das classes em vermelho e em laranja o Excel para alimentação do *Power BI*.

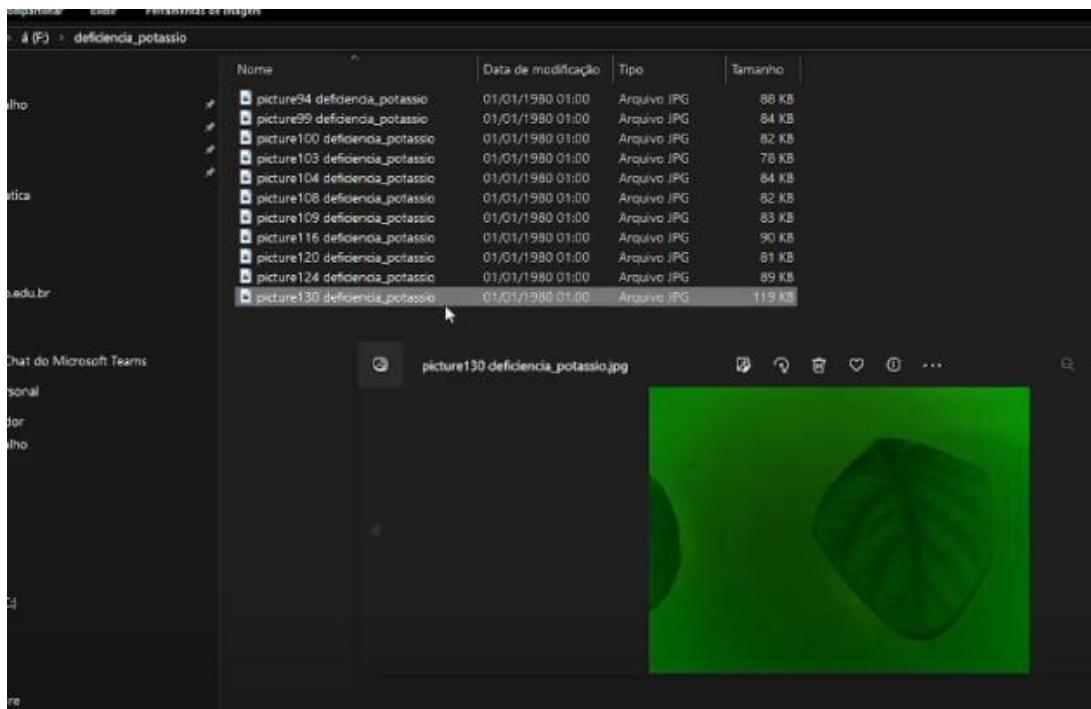
Figura 64 - Pasta do Cartão de Memória

Nome	Data de modificação	Tipo	Tamanho
.android_secure	20/05/2024 22:15	Pasta de arquiv...	
Android	20/05/2024 22:15	Pasta de arquiv...	
deficiencia_potassio	21/05/2024 23:07	Pasta de arquiv...	
ferrugem_asiatica	08/06/2024 00:18	Pasta de arquiv...	
LOST.DIR	20/05/2024 22:15	Pasta de arquiv...	
mancha_alvo	08/06/2024 16:12	Pasta de arquiv...	
olho_de_ra	08/06/2024 00:18	Pasta de arquiv...	
saudavel	21/05/2024 23:07	Pasta de arquiv...	
0		Arquivo	0 KB
00		Arquivo	0 KB
		Arquivo	0 KB
@0		Arquivo	0 KB
I	02/01/1984 01:00	Arquivo	0 KB
-		Arquivo	0 KB
*		Arquivo	0 KB
~00		Arquivo	0 KB
á		Arquivo	0 KB
à		Arquivo	0 KB
á		Arquivo	0 KB
dados	08/06/2024 23:01	Arquivo de Valo...	1 KB
é		Arquivo	0 KB

Fonte: Dos Autores, (2024)

Para verificar como as doenças foram classificadas pela rede, tem cada uma das pastas, que se encontram as imagens coletadas como visto um exemplo na Figura 65.

Figura 65 - Exemplo de Figura Classificada



Fonte: Dos Autores, (2024)

A Figura 66 apresenta a planilha Excel com dados do resultado de análise do algoritmo da IA embarcada no microcontrolador ESP 32 Cam, contendo latitude, longitude. Cada linha da planilha representa um registro individual, contendo a data e hora da análise e o resultado da classificação obtido.

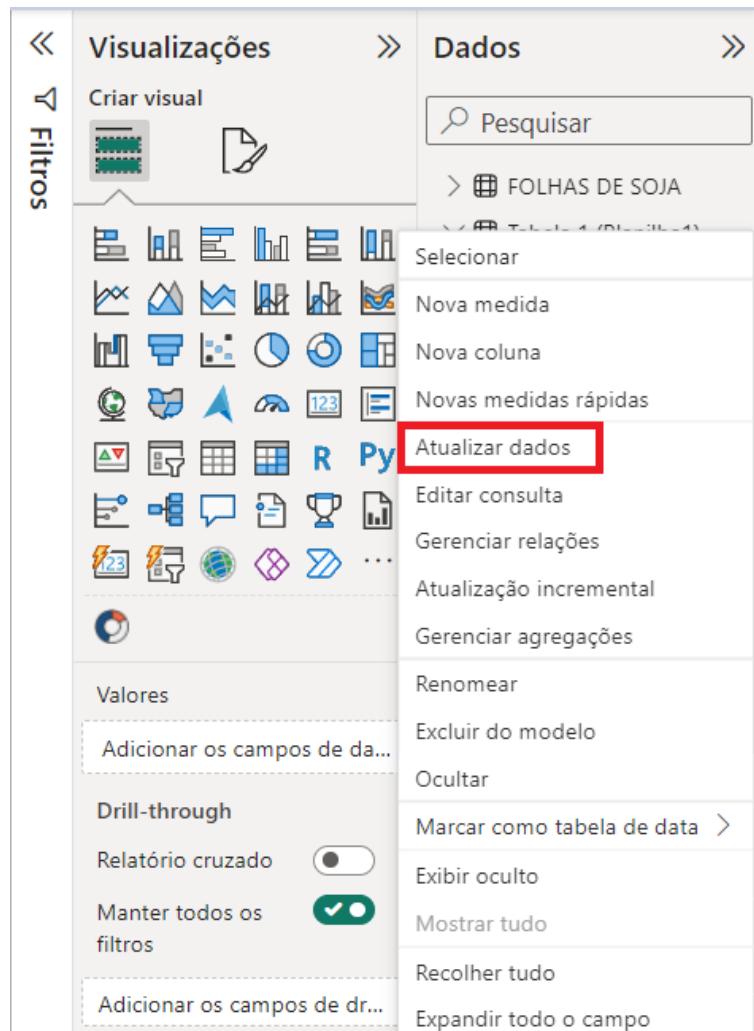
Figura 66 - Base Excel

	A	B	C	D	E
1	Lat	Long	Data/hora	Resultado	
2	-24,0097	-46,4318	09/06/2024 17:42	saudavel	
3	-24,0097	-46,4318	09/06/2024 17:42	saudavel	
4	-24,0097	-46,4318	09/06/2024 17:42	saudavel	
5	-24,0097	-46,4318	09/06/2024 17:42	saudavel	
6	-24,0097	-46,4318	09/06/2024 17:43	saudavel	
7	-24,0097	-46,4318	09/06/2024 17:43	saudavel	
8	-24,0097	-46,4318	09/06/2024 17:43	saudavel	
9	-24,0097	-46,4318	09/06/2024 17:43	saudavel	
10	-24,0097	-46,4318	09/06/2024 17:43	saudavel	
11	-24,0097	-46,4318	09/06/2024 17:44	saudavel	
12	-24,0097	-46,4318	09/06/2024 17:44	ferrugem_asiatica	
13	-24,0097	-46,4318	09/06/2024 17:44	saudavel	
14	-24,0097	-46,4318	09/06/2024 17:44	saudavel	
15	-24,0097	-46,4318	09/06/2024 17:44	ferrugem_asiatica	
16	-24,0097	-46,4318	09/06/2024 17:44	ferrugem_asiatica	
17	-24,0097	-46,4318	09/06/2024 17:45	ferrugem_asiatica	
18	-24,0097	-46,4318	09/06/2024 17:45	ferrugem_asiatica	

Fonte: Dos Autores, (2024)

Para atualização da base de dados basta selecionar todos os valores dessa nova planilha e substituir onde estão os valores coletados anteriormente na tabela usada para alimentação do BI. Com a planilha atualizada dos valores ao abrir o BI basta atualizar dados como exibido na Figura 67.

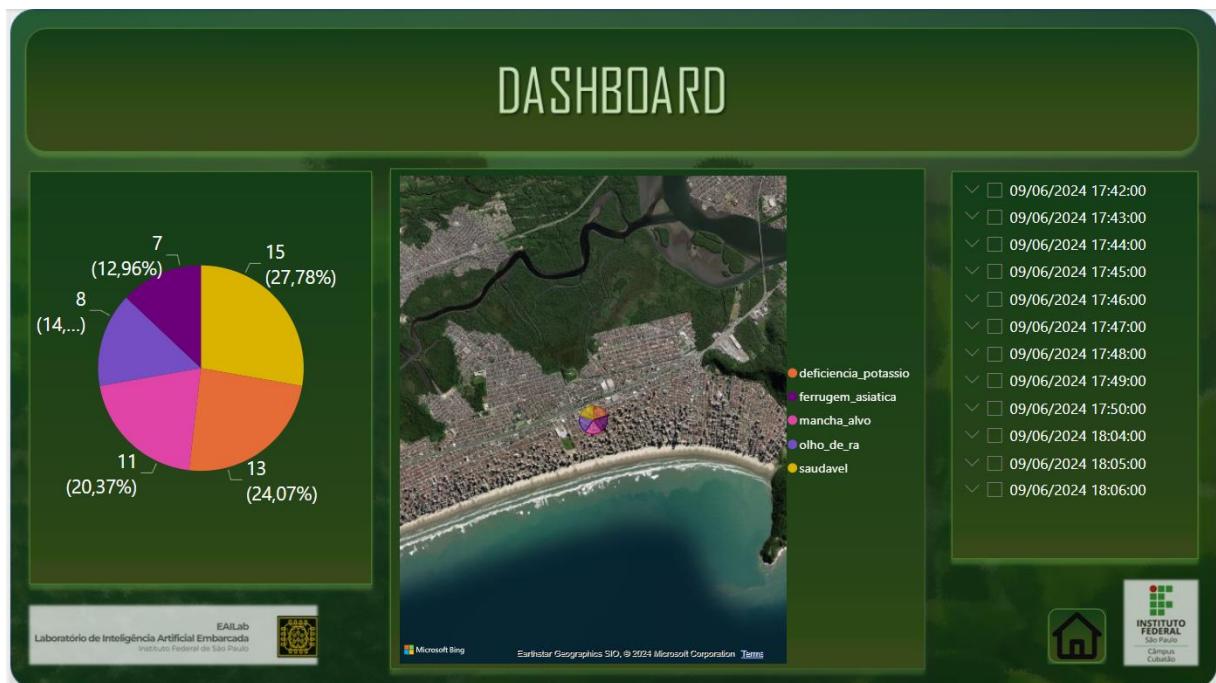
Figura 67 - Atualização de Dados BI



Fonte: Dos Autores, (2024)

Dessa forma a aplicação já está atualizada e pronta para análise dos resultados, que como visto na Figura 68 à esquerda, um gráfico de pizza ilustra a distribuição percentual das categorias, totalizando as 54 amostras. À direita, um mapa destaca a localização das amostras, com marcações indicando a ocorrência de "deficiencia_potassio", "ferrugem_asiatica", "mancha_alvo" e "olho_de_ra", além da categoria "saudavel". Adicionalmente, um registro temporal no canto superior direito indica os horários das análises, realizadas em 9 de junho de 2024 e o horário da coleta.

Figura 68 - Dashboard do teste



Fonte: Dos Autores, (2024)

Na Figura 69 está o relatório gerado com os dados do teste, mostrando que a doença com maior incidência foi a Deficiência de Potássio com isso apresentou o manejo da doença e como proceder.

Figura 69 - Relatório gerado com os dados de teste

RELATÓRIO DE ANÁLISE GERAL DAS AMOSTRAS		
	DE	ATÉ
COLETA DE IMAGENS	09/06/2024	09/06/2024
INCIDÊNCIA		
SAUDÁVEL	15	
DEFICIÊCIA DE POTÁSSIO	13	
MANCHA ALVO	11	
OLHO DE RÃ	8	
FERRUGEM ASIÁTICA	7	
TOTAL DE AMOSTRAS	54	
INCIDÊNCIA DE DEFICIÊNCIA DE POTÁSSIO	13	
<p>A doença que mais apresentou incidência na coleta feita foi a Deficiência de Potássio</p> <p>*Coletar amostras representativas do solo da área afetada, seguindo as recomendações de um agrônomo ou técnico agrícola.</p> <p>*Enviar as amostras para um laboratório de confiança para análise de fertilidade do solo, com foco nos níveis de potássio.</p> <p>*Aplicar o fertilizante potássico recomendado, seguindo as doses e épocas de aplicação indicadas pelo agrônomo</p> <p>*Após tempo de tratamento estipulado pelo fertilizante utilizado, refazer a inferencia para identificar se a planta está Saudável</p>		
<p>AÇÕES REALIZADAS</p> <p>() Consulta com agrônomo</p> <p>() Aplicação de fungicida _____</p> <p>() Manejo da irrigação _____</p> <p>() Adubação (tipo e dose) _____</p> <p>() Controle de plantas daninhas</p> <p>Práticas de MID Implementadas:</p> <p>() Rotação de Culturas</p> <p>() Escolha de Cultivares Resistentes</p> <p>() Tratamento de Sementes</p> <p>() Monitoramento Regular da Lavoura</p>		
<p>Responsável pela Avaliação: Assinatura do Agricultor/Técnico:</p>		

Fonte: Dos Autores, (2024)

Detalhes sobre parte desse experimento estão publicados em um vídeo no YouTube (BARUSSO, 2024).

A matriz de confusão apresentada na Tabela 7, demonstra o desempenho de um modelo de classificação em cinco classes distintas de doenças em plantas: Saudável, Olho de Rã, Deficiência de Potássio, Mancha Alvo e Ferrugem Asiática.

O modelo obteve 100% de acerto na identificação de plantas saudáveis e com deficiência de potássio, indicando alta precisão nessas classes. No entanto, houve uma taxa de erro de 27,28% na classificação de plantas com Olho de Rã, com 9,09% sendo classificadas erroneamente como deficiência de potássio e 18,18% como mancha alvo.

A classe Mancha Alvo apresentou a maior taxa de erro, com 20% das plantas sendo classificadas incorretamente como saudáveis. A Ferrugem Asiática também teve erros de classificação, com 11,11% sendo confundidas com as classes Olho de Rã e Deficiência de Potássio.

A acurácia geral do modelo, que indica a proporção de classificações corretas em relação ao total, foi de 87,03%, sugerindo um bom desempenho geral, mas com necessidade de melhorias na identificação de Mancha Alvo e Olho de Rã.

Tabela 7 - Matriz de Confusão

	Saudável	Olho de Rã	Def. de Potássio	Mancha Alvo	Ferr. Asiática	Total
Saudável	100%	-	-	-	-	54
Olho de Rã	-	72,72%	9,09%	18,18%	-	Acertos
Def. de Potássio	-	-	100%		-	47
Mancha Alvo	-	-	20%	80%	-	Acurácia
Ferr. Asiática	-	-	11,11%	11,11%	77,77%	0,87037

Fonte: Dos autores, (2024).

5. CONSIDERAÇÕES FINAIS

Este trabalho apresentou o desenvolvimento de um sistema inteligente para a identificação de doenças foliares na cultura da soja, utilizando técnicas de Inteligência Artificial e Visão Computacional. O modelo de rede neural convolucional (CNN) desenvolvido na plataforma Edge Impulse alcançou uma acurácia inicial de 71,1% e após aumento na base de dados e modificações nas configurações de treinamento alcançou uma acurácia de 87,7%, superando o objetivo proposto de 85%.

A integração do ESP32-CAM, do *display* OLED e do módulo GPS Ublox NEO-6M em um protótipo portátil, alimentado por uma bateria recarregável, viabiliza a coleta de dados em campo de forma eficiente e autônoma. A caixa protetora impressa em 3D garante a durabilidade e a segurança dos componentes eletrônicos, permitindo o uso do sistema em diferentes condições ambientais.

O desenvolvimento de um *dashboard* no *Power BI* e relatório, oferecem uma interface intuitiva para a visualização e análise dos dados coletados, facilitando a interpretação das informações e a tomada de decisões pelos agricultores. A inclusão de cartilhas informativas sobre as doenças identificadas agrega valor ao sistema, fornecendo aos usuários informações relevantes sobre prevenção e tratamento.

As maiores dificuldades enfrentadas decorreram principalmente da variabilidade do ambiente de campo, como iluminação, ângulo da foto, sombra e tamanho da folha, fatores que impactam na acurácia final da rede. A busca contínua por aprimoramentos visa minimizar o impacto dessas adversidades e aumentar a robustez do sistema.

Para trabalhos futuros, vislumbra-se:

- a. ampliação da base de dados com imagens de diferentes cultivares de soja;
- b. a inclusão de novas doenças, como a antracnose, mencionada por um dos agricultores entrevistados, também é uma possibilidade promissora;
- c. desenvolvimento de uma base de dados web para armazenamento robusto de dados históricos para alimentação de planilha BI automatizada.

A realização de testes de campo em diversas regiões e condições climáticas permitirá validar o desempenho do protótipo em cenários reais, identificando possíveis ajustes necessários. A integração do sistema a drones ou outros equipamentos de pulverização possibilitará a aplicação precisa e direcionada de defensivos agrícolas, com base nas informações fornecidas pelo sistema de identificação de doenças.

6. REFERENCIAS

- AGROLINK. Mancha alvo (*Corynespora cassiicola*). Disponível em: https://www.agrolink.com.br/problemas/mancha-alvo_1724.html. Acesso em: 05 abr. 2024.
- BARBEDO, Jayme Garcia Arnal; KOENIGKAN, Luciano Vieira; SANTOS, Thiago Teixeira. Identifying multiple plant diseases using digital image processing. *Biosystems engineering*, v. 147, p. 104-116, 2016. Disponível em: <https://doi.org/10.1016/j.biosystemseng.2016.03.012>. Acesso em: 19 mai. 2024.
- BHATTACHARYA, Saurabh; PANDEY, Manju. Deploying an energy efficient, secure & high-speed sidechain-based TinyML model for soil quality monitoring and management in agriculture. *Expert Systems with Applications*, v. 242, p. 122735, 2024. Disponível em: <https://doi.org/10.1016/j.eswa.2023.122735>. Acesso em 19 mai. 2024.
- BEVERS, Noah; SIKORA, Edward J.; HARDY, Nate B. Soybean disease identification using original field images and transfer learning with convolutional neural networks. *Computers and Electronics in Agriculture*, v. 203, p. 107449, 2022. Disponível em: <https://doi.org/10.1016/j.compag.2022.107449>. Acesso em 19 mai. 2024.
- BOTOEVA, Elena; KOUVAROS, Panagiotis; KRONQVIST, Jan; LOMUSCIO, Alessio; MISENER, Ruth. Efficient verification of relu-based neural networks via dependency analysis. In: *Proceedings of the AAAI Conference on Artificial Intelligence*. 2020. p. 3291-3299. Disponível em: <https://doi.org/10.1609/aaai.v34i04.5729>. Acesso em: 19 mai. 2024.
- BRASIL. Ministério da Agricultura, Pecuária e Abastecimento (MAPA). Portaria SDA nº 640, de 28 de setembro de 2023. Dispõe sobre o vazio sanitário da cultura da soja na safra 2023/2024. Brasília, DF: MAPA, 2023. Disponível em: <https://www.gov.br/agricultura/pt-br/assuntos/insumos-agropecuarios/insumos-agricolas/sementes-e-mudas/vazio-sanitario-da-soja>. Acesso em: 04 jun. 2024.
- BROWN, C., Follings, J., Moran, M., and Rosser, B. (Eds.) 2022. *Agronomy guide for field crops*. Publication 811E. Ontario Ministry of Agriculture, Food, and Rural Affairs. Disponível em: <https://www.ontario.ca/page/agronomy-guide-field-crops#section-1>. Acesso em: 19 mai. 2024.
- CAO, Keyan; LIU, Yefan; MENG, Gongjie; SUN, Qimeng. An overview on edge computing research. *IEEE access*, v. 8, p. 85714-85728, 2020. Disponível em: [10.1109/ACCESS.2020.2991734](https://doi.org/10.1109/ACCESS.2020.2991734). Acesso em: 19 mai. 2024.
- BARUSSO, CAROLINA. Sistema inteligente para identificação de doenças foliares na cultura de soja. Youtube. 2024. Disponível em: <https://www.youtube.com/watch?v=znPjoXWZ0eM>

Coordenadoria de Defesa Agropecuária (CDA). 2024. Sanidade Vegetal: Após mudança no calendário, começa no sábado, dia 1º, o Vazio Sanitário da Soja na Região 1 do Estado de São Paulo. <https://www.defesa.agricultura.sp.gov.br/noticias/2024/sanidade-vegetal-apos-mudanca-no-calendario-comeca-no-sabado-dia-1-o-vazio-sanitario-da-soja-na-regiao-1-do-estado-de-sao-paulo,2123.html> Acesso em: 30 mai. 2024.

COSTA, FERNANDA DE SOUZA, et al. "Diagnóstico de doenças foliares de soja: uma ferramenta essencial para o manejo integrado." **Planta Daninha**, vol. 38, no. 4, pp. 1059-1068, 2020.

DHARMADHIKARI, Abhishek; KHAIRE S.; YERKAL S.; ATTAR, V.Z.; KALAMKAR, S. A comprehensive survey of weed detection methodologies in soybean crop. In: 2023 3rd Asian Conference on Innovation in Technology (ASIANCON). IEEE, 2023. p. 1-7. Disponível em: 10.1109/ASIANCON58793.2023.10270790. Acesso em: 20 mai. 2024.

DONG, B.; QIONGFENG, Shi; YANG, Yangjin; WEN, Feng; ZHANG, Zixuan; LEE, Chengkuo. Technology evolution from self-powered sensors to IoT enabled smart homes. *Nano Energy*, Elsevier, v. 79, p. 105414, 2021. Disponível em: <https://doi.org/10.1016/j.nanoen.2020.105414>. Acesso em: 19 mai. 2024.

Edge Impulse. Edge Impulse Python SDKEdge Impulse, 2024. Edge Impulse Python SDK. Disponível em: <https://docs.edgeimpulse.com/docs/tools/edge-impulse-python-sdk>. Acesso em 21 ago .2024

EDGE IMPULSE, Build. Train. Optimize. AI for the edge. Disponível em: <https://www.edgeimpulse.com>. Acesso em: 19 mai. 2024.

EMBRAPA. Manejo de doenças na soja. Londrina: Embrapa Soja, 2024. 2 p. Folder ilustrado. Disponível em: <https://www.embrapa.br/en/busca-de-publicacoes-/publicacao/915966/manejo-de-doencas-na-soja>. Acesso em: 10 mar. 2024.

FARMOVÁ, Nizom; AMANKULOVÁ, Khilola; SZATMÁRI, József; SHARIFI, Alireza; ABBASI-MOGHADAM, Dariush; NEJAD, S. M. M.; MUCSI, László. Crop type classification by DESIS hyperspectral imagery and machine learning algorithms. *IEEE Journal of selected topics in applied earth observations and remote sensing*, v. 16, p. 1576-1588, 2023. Disponível em: 10.1109/JSTARS.2023.3239756. Acesso em: 19 mai. 2024.

FENG, Fukang; GAO, Maofang; LIU, Ronghua; YAO, Shuihong; YANG, Guijun. A deep learning framework for crop mapping with reconstructed sentinel-2 time series images. *Computers and Electronics in Agriculture*, v. 213, p. 108227, 2023. Disponível em: <https://doi.org/10.1016/j.compag.2023.108227>. Acesso em: 19 mai. 2024.

FERREIRA, A. S.; FREITAS, D. M.; SILVA, G. G.; PISTORI, H.; FOLHES, M. T. (2017). Weed detection in soybean crops using ConvNets. *Computers and*

Electronics in Agriculture, 143, 314-324. ISSN 0168-1699. Disponível em: <https://doi.org/10.1016/j.compag.2017.10.027>. Acesso em 19 mai. 2024.

GHARGE, Saylee; SINGH, Priyanka. Image processing for soybean disease classification and severity estimation. Emerging Research in Computing, Information, Communication and Applications: ERCICA 2015, Volume 2. Springer India, 2016. p. 493-500. Disponível em: https://doi.org/10.1007/978-81-322-2553-9_44. Acesso em 19 mai. 2024.

GRÜBLER, M. (2019). Entendendo o funcionamento de uma Rede Neural Artificial. Brasil AI (Medium). <https://medium.com/brasil-ai/entendendo-o-funcionamento-de-uma-rede-neural-artificial-4463fcf44dd0>. Acesso em: 10 jun. 2024

GY-NEO6MV2. Flight Control GPS Module. Disponível em: <https://www.datasheethub.com/gy-neo6mv2-flight-control-gps-module/> Acesso: 29 mar. 2024.

HAGAN, Martin T.; DEMUTH, Howard B.; BEALE, Mark. **Neural network design**. Martin Hagan; 2º edition, 2014, 802 p. Disponível em: <https://dl.acm.org/doi/abs/10.5555/2721661>. Acesso em: 19 mai. 2024.

HAIXIANG, G.; YIJING, L.; SHANG, J.; MINGYUN, G.; YUANYUE, H. Learning from class-imbalanced data: Review of methods and applications. Expert Systems with Applications, 73:220–239, 2017. Disponível em: <https://doi.org/10.1016/j.eswa.2016.12.035>. Acesso em: 19 mai. 2024.

HENNING, A. A.; ALMEIDA, A. M. R; GODOY, C. V.; SEIXAS, C. D. S.; YORINORI, J. T.; COSTAMILAN, L M.; FERREIRA L. P.; MEYER M. C.; SOARES R M.; DIAS W. P. Manual de identificação de doenças de soja. Documentos 256: Embrapa, 2014, 78 p. Disponível em: <https://www.embrapa.br/en/busca-de-publicacoes-/publicacao/991687/manual-de-identificacao-de-doencas-de-soja>. Acesso em: 20 mai. 2024.

HYMEL, S.; BANBURY, C.; SITUNAYAKE, D.; ELIUM, A.; WARD, C.; KELCEY, M.; REDDI, V. J. et al. Edge impulse: An mlops platform for tiny machine learning. Cornell University, Computer Science: Distributed, Parallel, and Cluster Computing, 2022. Disponível em: <https://doi.org/10.48550/arXiv.2212.03332>. Acesso em: 19 mai. 2024.

HUANG, Z.; WANG, R.; CAO, Y.; ZHENG, S.; TENG, Y.; WANG, F.; WANG, L.; DU, J. Deep learning based soybean seed classification. Computers and Electronics in Agriculture, v. 202, p. 107393, 2022. Disponível em: <https://doi.org/10.1016/j.compag.2022.107393>. Acesso em: 19 mai. 2024.

HURLBURT, G. F. Low-Code, No-Code, What's Under the Hood?. IT Professional, vol. 23, no. 6, p. 4-7, 2021. Disponível em: <https://doi.org/10.1109/MITP.2021.3123415>. Acesso em: 19 mai. 2024.

IODICE, G. M. TinyML Cookbook: Combine artificial intelligence and ultra-low-power embedded devices to make the world smarter. [S. I.]: Packt, 2022. ISBN 9781801814973. Disponível em: <https://www.packtpub.com/product/tinyml-cookbook/9781801814973>. Acesso em: 19 mai. 2024.

JAFARI, Amir H.; HAGAN, Martin T. Application of new training methods for neural model reference control. *Engineering Applications of Artificial Intelligence*, v. 74, p. 312-321, 2018. Disponível em: <https://doi.org/10.1016/j.engappai.2018.07.005>. Acesso em: 19 mai. 2024.

KUSSUL, Nataliia et al. The use of satellite SAR imagery to crop classification in Ukraine within JECAM project. In: 2014 IEEE Geoscience and Remote Sensing Symposium. IEEE, 2014. p. 1497-1500. Disponível em: <https://doi.org/10.1109/IGARSS.2014.6946721>. Acesso em: 19 mai. 2024.

LABORATÓRIO MAXWELL. WMO - Workshop de Micro-ondas 2023. Disponível em: <https://labmax.org/index.php/wmo/>. Acesso em: 6 jun. 2024.

LIN, Wei et al. Soybean image dataset for classification. *Data in Brief*, v. 48, p. 109300, 2023. Disponível em: <https://doi.org/10.1016/j.dib.2023.109300>. Acesso em: 19 mai. 2024.

LITER ENERGY BATTERY. SD 303040 3.7V 450mAh bateria recarregável de polímero de lítio com placa de proteção. Disponível em: <https://pt.aliexpress.com/item/1005004289086217.html>. Acesso em: 5 jun. 2024.

LUO, Chen et al. OB-ConvLSTM: A sequential remote sensing crop classification model with OBIA and ConvLSTM models. 2023 11th International Conference on Agro-Geoinformatics (Agro-Geoinformatics). IEEE, 2023. p. 1-6. Disponível em: <https://doi.org/10.1109/Agro-Geoinformatics59224.2023.10233296>. Acesso em: 19 mai. 2024.

MARKELL, Samuel G.; MALVICK, Dean. Soybean disease diagnostic series. NDSU Extension Service, 2018. Disponível em: <https://www.ndsu.edu/agriculture/extension/publications/soybean-disease-diagnostic-series>. Acesso em: 20 mai. 2024.

MATHWORKS. How CNNs Work. [S. I.: s. n.], 2020. Disponível em: <https://www.mathworks.com/discovery/convolutional-neural-network.html#:~:text=Tutorials%20and%20examples-,How%20CNNs%20Work,input%20to%20the%20next%20layer>. Acesso em: 29 fev. 2024.

MICROSOFT. Power BI. Disponível em https://powerbi.microsoft.com/pt-br/landing/free-account/?ef_id=_k_Cj0KCQjwk6SwBhDPARIsAJ59GwcQB8nzxs_hYakxzoZ3TNk

AT4FiFH6VE1X1PW0TfinCQMVhYKIMvhkaAvFjEALw_wcB_k_&OCID=AIDcmmk4cy2ahx_SEM_k_Cj0KCQjwk6SwBhDPARIsAJ59GwcQB8nzxs_hYakxzoZ3TNk AT4FiFH6VE1X1PW0TfinCQMVhYKIMvhkaAvFjEALw_wcB_k_&gad_source=1&gclid=Cj0KCQjwk6SwBhDPARIsAJ59GwcQB8nzxs_hYakxzoZ3TNkAT4FiFH6VE1 X1PW0TfinCQMVhYKIMvhkaAvFjEALw_wcB. Acesso em: 31 mar. 2024.

MIHIGO, Irene Niyonambaza et al. On-device iot-based predictive maintenance analytics model: Comparing tinylstm and tinymlmodel from edge impulse. Sensors, v. 22, n. 14, p. 5174, 2022. Disponível em: <https://doi.org/10.3390/s22145174>. Acesso em: 20 mai. 2024.

NICOLAS, Chollet; NAILA, Bouchemal; AMAR, Ramdane-Cherif. Tinyml smart sensor for energy saving in internet of things precision agriculture platform. 2022 Thirteenth International Conference on Ubiquitous and Future Networks (ICUFN). IEEE, 2022. p. 256-259. Disponível em: <https://doi.org/10.1109/ICUFN55119.2022.9829675>. Acesso em: 20 mai. 2024.

NAÇÕES UNIDAS. População mundial deve ter mais 2 bilhões de pessoas nos próximos 30 anos. ONU News, 17 jun. 2019. Disponível em: <https://news.un.org/pt/story/2019/06/1071822>. Acesso em: 20 maio 2024.

ORUMA, Samson O.; MISRA, Sanjay; FERNANDEZ-SANZ, Luis. Agriculture 4.0: an implementation framework for food security attainment in Nigeria's post-Covid-19 era. Ieee Access, v. 9, p. 83592-83627, 2021. Disponível em: <https://doi.org/10.1109/ACCESS.2021.3086453>. Acesso em: 20 mai. 2024.

PERIODICOS. Portal de Periódicos CAPES. Disponível em: <https://www.periodicos.capes.gov.br/>. Acesso em: 19 maio 2024.

RANDOM NERDS. Tutorial de uso do ESP32 CAM. Disponível em: <https://randomnerdtutorials.com/esp32-cam-video-streaming-face-recognition-arduino-ide/> Acesso: 29 mar 2024.

REIS, Ângelo Vieira dos et al. Technological trends in digital agriculture and their impact on agricultural machinery development practices. Revista Ciência Agronômica, v. 51, n. spe, p. e20207740, 2020. Disponível em: <https://doi.org/10.5935/1806-6690.20200093>. Acesso em: 20 mai. 2024.

Remote Sensing, v. 9, n. 8, p. 3712-3719, 2015. Disponível em: <https://doi.org/10.1109/JSTARS.2015.2454297>. Acesso em: 20 mai. 2024.

ROBÔ MARTE. Display OLED 0.96" I2C Módulo 128x64. Disponível em: <https://robomarte.com.br/produtos/display-oled-0-96-i2c-modulo-128x64/>. Acesso em: 5 jun. 2024.

SANCHEZ-IBORRA, R.; SKARMETA, A. F. Tinyml-enabled frugal smart objects: Challenges and opportunities. IEEE Circuits and Systems Magazine, IEEE, v. 20, n. 3, p. 4–18, 2020.

SCOPUS. Scopus. Disponível em: <https://www.scopus.com/>. Acesso em: 19 maio 2024.

SHINDE, Pramila P.; SHAH, Seema. A review of machine learning and deep learning applications. 2018 Fourth international conference on computing communication control and automation (ICCUBEA). IEEE, 2018. p. 1-6. Disponível em: <https://doi.org/10.1109/ICCUBEA.2018.8697857>. Acesso em: 19 mai. 2024.

SIDIKE, P.; Sagan, V.; MAIMAITIJIANG, M.; MAIMAITIYIMING, M.; SHAKOOR, N.; BURKEN, J.; MOCKLER, T.; FRITSCHI, F. B. (2019). dPEN: deep Progressively Expanded Network for mapping heterogeneous agricultural landscape using WorldView-3 satellite imagery. *Remote sensing of environment*, v. 221, p. 756-772, 2019. Disponível em: <https://doi.org/10.1016/j.rse.2018.11.031>. Acesso em: 20 mai. 2024.

SKAKUN, Sergii et al. Efficiency assessment of multitemporal C-band Radarsat-2 intensity and Landsat-8 surface reflectance satellite imagery for crop classification in Ukraine. *IEEE Journal of Selected Topics in Applied Earth Observations and*

TERLİKSİZ, Anıl Suat; ALTÝLAR, D. Turgay. Use of deep neural networks for crop yield prediction: A case study of soybean yield in lauderdale county, alabama, usa. 2019 8th international conference on Agro-Geoinformatics (Agro- Geoinformatics). IEEE, 2019. p. 1-4. Disponível em: <https://doi.org/10.1109/Agro-Geoinformatics.2019.8820257>. Acesso em: 20 mai. 2024.

VARGHESE, B. et al. Challenges and Opportunities in Edge Computing. In: 2016 IEEE International Conference on Smart Cloud (SmartCloud). [S. I.: s. n.], 2016. P. 20–26. Disponível em: <https://doi.org/10.1109/SmartCloud.2016.18>. Acesso em: 19 mai. 2024.

VEERANAMPALAYAM SIVAKUMAR, Arun Narendhiran et al. Comparison of object detection and patch-based classification deep learning models on mid-to late-season weed detection in UAV imagery. *Remote Sensing*, v. 12, n. 13, p. 2136, 2020. Disponível em: <https://doi.org/10.3390/rs12132136>. Acesso em: 19 mai. 2024.

WANG, Ya-Hong; SU, Wen-Hao. Convolutional neural networks in computer vision for grain crop phenotyping: A review. *Agronomy*, v. 12, n. 11, p. 2659, 2022. Disponível em: <https://doi.org/10.3390/agronomy12112659>. Acesso em: 20 mai. 2024.

WANG, J., WANG, Y., & LIU, X. Image classification for precision agriculture: A survey of methods and applications. *Sensors*, 2020.

XIN, Mingyuan; WANG, Yong. An image recognition algorithm of soybean diseases and insect pests based on migration learning and deep convolution network. In: 2020 International Wireless Communications and Mobile Computing (IWCMC).

IEEE, 2020. p. 1977-1980. Disponível em: <https://doi.org/10.1109/IWCMC48107.2020.9148331>. Acesso em: 20 mai. 2024.

YAN, Yulin; RYU, Youngryel. Exploring Google Street View with deep learning for crop type mapping. *ISPRS Journal of Photogrammetry and Remote Sensing*, v. 171, p. 278-296, 2021. Disponível em: <https://doi.org/10.1016/j.isprsjprs.2020.11.022>. Acesso em: 20 mai. 2024.

ZHANG, S., LIU, X., WANG, Y., & WANG, H Classification of soybean leaf diseases using hyperspectral imagery. **IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing**, 2021.

ANEXOS

Anexo I - Artigo Publicado



Instituto Federal de Educação, Ciência e Tecnologia de São Paulo
Laboratório Maxwell de Micro-ondas e Eletromagnetismo Aplicado
 Anais do Workshop de Micro-ondas DOI: 10.5281/zenodo.10051323 ISSN 2675-4460

CLASSIFICATION OF SOYBEAN LEAVES USING THE EDGE IMPULSE PLATFORM

Carolina Barusso de Oliveira¹, Dr. Walter Augusto Varella¹, Jane Piantoni¹ and Rogerio Daniel Dantas¹.

IFSP – c.barusso@aluno.ifsp.edu.br, IFSP –varella@ifsp.edu.br, Jane.Piantoni@fit-tecnologia.org.br, rogerio.dantas@ifsp.edu.br

Summary- Modern agriculture increasingly relies on technology, including artificial intelligence (AI) image classification, to improve crop management. This study focuses on applying image classification to diagnose diseases in soybean leaves using a convolutional neural network. The results show 95% accuracy in identifying healthy and diseased leaves, indicating the potential of AI as an effective tool for monitoring crop health.

Key words: image classification, artificial intelligence, agriculture, soybeans, leaf diseases

INTRODUCTION

Uncertainty about the health of soybean plants is a persistent challenge for farmers, given the economic relevance and growing demand for this crop in global agricultural scenarios. Soy plays a key role in both food and feed production, making its health essential for food security and the economy [1].

A soybean agriculture faces significant challenges, including the spread of specific diseases that can reduce production and increase management costs. Diseases such as Asian rust and powdery mildew can spread quickly, causing substantial losses to farmers. Therefore, early and effective detection of these diseases is of utmost importance for modern soybean agriculture [1].

Before the advent of artificial intelligence and computer vision, farmers relied primarily on visual observation to detect diseases in soybean plants. This approach was prone to human error and often resulted in inaccurate diagnoses. Furthermore, it was difficult to monitor large areas of cultivation efficiently. This made disease detection and management a constant challenge for farmers [2].

The characteristics of diseased soybean leaves can vary depending on the type of pathogen affecting them, but they usually have visible signs that indicate health problems [3]. Diseased soybean leaves often exhibit changes in color, such as yellow or brown spots or necrosis in certain areas. Furthermore, they may have irregular textures, with roughness, wrinkles or deformations.

Visible lesions such as pustules, mold spots or insect marks are also common on diseased leaves. These diseases not only reduce plant productivity but also increase production costs due to excessive use of pesticides [3]. In Fig. 1 it is possible to identify some of these characteristics



Figure 1 – Sick Soybean Leaf [7].

Accurate identification of these characteristics plays a key role in early detection and differentiation of healthy soybean leaves from those affected by disease, enabling effective intervention to ensure plant health and crop productivity and positive implications for the environment and agricultural sustainability. Reduced pesticide use resulting from early detection contributes to reduced environmental contamination and promotes more sustainable agricultural practices [3].

In this context, the project aims to classify images of soybean leaves, with the aim of distinguishing those that are healthy from those affected by diseases. To perform this task, the "SoyNet" dataset was used. This dataset includes images of healthy and diseased soybean leaves, which were captured in Jabalpur under natural light conditions using a Nikon L810 camera and a Motorola g40 cell phone. The images went through a pre-processing process, being converted to grayscale and resized to a resolution of 256x256 pixels [4].

In Fig. 2, the images captured without any type of prior treatment are shown, that is, the original images. In Fig. 3, the same images are found after having gone through the pre-processing process. This prior treatment is essential to prepare the images before they are used in the classification process.

APÊNDICE

Apêndice I - Tendências e Desafios na Agricultura de Soja: Um Questionário sobre Manejo de Doenças e Práticas Culturais

INFORMAÇÕES GERAIS

Nesta primeira parte do questionário, nosso objetivo é obter uma compreensão abrangente das práticas agrícolas relacionadas à produção de soja em sua fazenda. Estamos interessados em diversos aspectos, como os custos médios de insumos, a prevalência de doenças locais, os métodos de plantio adotados e outros fatores que impactam diretamente na produtividade e na gestão eficiente da sua plantação de soja.

The screenshot shows a digital survey form. At the top, there is a header with the logos of the Instituto Federal de São Paulo (Câmpus Guarulhos) and the EIALab (Laboratório de Inteligência Artificial Empresarial). Below the header is a scenic image of a soybean field at sunset. A navigation bar at the bottom left indicates 'Seção 1 de 2'. The main title of the survey is displayed prominently in the center. Below the title, there are icons for bold, italic, underline, and other document-related functions. A message of thanks is present, followed by a detailed explanation of the survey's purpose. At the bottom, it lists the names of the project members and their advisor.

Tendências e Desafios na Agricultura de Soja: Um Questionário sobre Manejo de Doenças e Práticas Culturais

B I U ⊖ ✎

Primeiramente agradecemos pela participação e colaboração em nosso projeto.

Este questionário tem como objetivo coletar informações sobre o perfil dos produtores de soja, suas práticas de cultivo e os desafios enfrentados no manejo de doenças. As respostas fornecidas serão fundamentais para embasar o desenvolvimento do Projeto Final de Curso, cujo tema é: "Sistema Inteligente para Detecção de Doenças Foliares na Cultura de Soja".

Os integrantes são:
 Carolina Barusso
 Leonardo Knoeller
Sob orientação de:
 Dr. Arnaldo de Carvalho
 Dr. Walter Augusto Varella

INFORMAÇÕES GERAIS

Nesta primeira parte do questionário, nosso objetivo é obter uma compreensão abrangente das práticas agrícolas relacionadas à produção de soja em sua fazenda. Estamos interessados em diversos aspectos, como os custos médios de insumos, a prevalência de doenças locais, os métodos de plantio adotados e outros fatores que impactam diretamente na produtividade e na gestão eficiente da sua plantação de soja.

Nome: *

Texto de resposta curta

Localização da Plantação *

Texto de resposta curta

Tempo de experiência com a cultura da soja *

- Menos de 5 anos
- 5 - 10 anos
- 11- 20 anos
- Mais de 20 anos

Quais métodos de cultivo você utiliza na sua plantação de soja?

- Convencional
- Plantio Direto
- Outros...

Quais doenças que afetam a folha de soja são mais comuns na sua região?

- Ferrugem Asiática
- Mancha Alvo
- Deficiência de Potássio
- Olho de rã
- Outros...

Quais medidas preventivas você adota para evitar doenças na sua plantação?

- Rotação de Culturas
- Uso de Cultivares Resistentes
- Monitoramento Regular
- Outros...

Quais são os principais desafios que você enfrenta na sua prática de cultivo?

Texto de resposta longa

Qual é o impacto financeiro das doenças na sua plantação de soja em termos de perdas de produtividade e custos adicionais de tratamento?

1

2

3

4

5

Baixo

Muito Alto

Qual é o investimento anual médio em prevenção e tratamento de doenças na plantação de soja?

Texto de resposta curta

Qual é a parcela aproximada dos gastos totais da sua fazenda destinada a insumos agrícolas, como fertilizantes e defensivos? (Em porcentagem)

Texto de resposta curta

Como você avalia de 1 a 5 a relação custo-benefício das medidas que adota para manejo de doenças?

1

2

3

4

5

Baixo Custo-Benefício

Alto Custo-Benefício

Seção 2 de 2**TECNOLOGIA NO AGRO**

Estas perguntas têm como objetivo fornecer uma base para compreender as medidas tecnológicas implementadas nas fazendas, visando o desenvolvimento de um Dashboard e relatórios que se concentrem nos aspectos mais relevantes. Pedimos que responda com a maior riqueza de detalhes possível, pois será fundamental na decisão para escolha dos gráficos e tabelas para análise.

Quais das seguintes tecnologias foram implementadas em sua fazenda?

- Internet das Coisas
- Irrigação Inteligente
- Inteligência Artificial
- Pulverização com Drones
- Analise de Dados com Excel
- Analise de Dados com Power BI
- Outros...

Quanto é investido em média para aprimoramento da gestão da fazenda? (Em porcentagem)

Texto de resposta longa

Você utiliza alguma ferramenta ou software para simplificar a gestão administrativa?

Texto de resposta longa

Quais relatórios a seguir são gerados para controle e abastecimento da fazenda?

- Gestão de Sementes
- Gestão de doenças por localização
- Gestão da Irrigação
- Gestão de nutrientes
- Gestão de produtos defensivos

Em uma escala de 1 a 5 quão automatizada é a sua fazenda?

1 2 3 4 5

Mínima Automação

Totalmente Automatizada

Você utiliza alguma tecnologia ou inovação específica para monitoramento e controle de doenças na sua plantação?

Texto de resposta curta

Se a resposta da pergunta anterior foi SIM, então há quanto tempo utiliza essa tecnologia e quais resultados foram observados com a implementação?

Texto de resposta longa

Descreva o que sua fazenda possui de automação.

Texto de resposta longa

Como você acompanha as informações sobre novas doenças e técnicas de manejo?

- Capacitações e treinamentos
- Consultoria especializada
- Pesquisas e estudos científicos
- Outros...

Há mais alguma informação que você gostaria de compartilhar sobre o manejo de doenças na sua plantação de soja?

Texto de resposta longa

Apêndice II – Código fonte para realização do projeto

INFORMAÇÕES GERAIS

Este código utiliza a câmera do ESP32-CAM para capturar fotos, o GPS GY-NEO 6M é responsável por adquirir informações de data, hora, latitude e longitude, que serão utilizadas para um arquivo “.csv”, o *display LCD OLED 0.96* tem a função de informar os dados que o GPS está capturando para o usuário. No momento de captura da foto, o código gera um arquivo de lista “.csv” que é associado a foto capturada, juntando informações de horário e classificação (Saudável, Ferrugem Asiática, Deficiência de Potássio, Olho de Rã e Mancha Alvopara que essas informações possam ser utilizadas no Power BI, posteriormente.

O ambiente de desenvolvimento utilizado foi o Arduino IDE.

```
#include "esp_camera.h"
#include "Arduino.h"
#include "FS.h"
#include "SD_MMC.h"
#include "soc/soc.h"
#include "soc/rtc_cntl_reg.h"
#include "driver/rtc_io.h"
#include <EEPROM.h>
#include <TinyGPS++.h>
#include <Wire.h>
#include <Adafruit_GFX.h>
#include <Adafruit_SSD1306.h>
#include <Soja2024_v1_inferencing.h>
#include "edge-impulse-sdk/dsp/image/image.hpp"

// Definições de Hardware (configuração da câmera)
#define CAMERA_MODEL_AI_THINKER

#include <Wire.h>
#include <Adafruit_GFX.h>
#include <Adafruit_SSD1306.h>

#define I2C_SDA 15
#define I2C_SCL 14
TwoWire I2Cbus = TwoWire(0);

#define SCREEN_WIDTH 128
#define SCREEN_HEIGHT 64
#define OLED_RESET -1
#define SCREEN_ADDRESS 0x3C

/* Definições para captura da Imagem ----- */
#define EI_CAMERA_RAW_FRAME_BUFFER_COLS 320
#define EI_CAMERA_RAW_FRAME_BUFFER_ROWS 240
#define EI_CAMERA_FRAME_BYTE_SIZE 3

// Variáveis para manipulação da imagem e controle da captura
static bool debug_nn = false;
static bool is_initialised = false;
uint8_t *snapshot_buf;
```

```

// Configuração da Câmera
static camera_config_t camera_config = {
    // ... (configurações de PIN da câmera)
    .xclk_freq_hz = 20000000,
    .ledc_timer = LEDC_TIMER_0,
    .ledc_channel = LEDC_CHANNEL_0,
    .pixel_format = PIXFORMAT_JPEG,
    .frame_size = FRAMESIZE_QVGA,
    .jpeg_quality = 12,
    .fb_count = 1,
    .fb_location = CAMERA_FB_IN_PSRAM,
    .grab_mode = CAMERA_GRAB_WHEN_EMPTY,
};

// Configurações de Hardware (GPS e OLED)
static const int RXPin = 34, TXPin = 32;
static const uint32_t GPSBaud = 9600;
TinyGPSPlus gps;
HardwareSerial SerialGPS(1);
#define SCREEN_WIDTH 128
#define SCREEN_HEIGHT 64
Adafruit_SSD1306 display(SCREEN_WIDTH, SCREEN_HEIGHT, &Wire, -1);

// Funções para inicializar/desligar a câmera e capturar a imagem
bool ei_camera_init(void);
void ei_camera_deinit(void);
bool ei_camera_capture(uint32_t img_width, uint32_t img_height, uint8_t *out_buf) ;

int pictureNumber = 0;

void setup() {
    Serial.begin(115200);

    // Inicialização da Câmera
    while (!Serial);
    Serial.println("Edge Impulse Inferencing Demo");
    if (ei_camera_init() == false) {
        Serial.println("Failed to initialize Camera!");
    } else {
        Serial.println("Camera initialized");
    }

    // Inicialização do GPS
    SerialGPS.begin(GPSBaud, SERIAL_8N1, RXPin, TXPin);

    // Inicialização do OLED
    if(!display.begin(SSD1306_SWITCHCAPVCC, 0x3C)) {
        Serial.println(F("SSD1306 allocation failed"));
        for(;;);
    }
}

```

```

display.clearDisplay();
display.display();

// Carregar o número da foto da EEPROM (memória não volátil)
pictureNumber = EEPROM.read(0); // Lê o número da foto armazenado na posição 0 da
EEPROM
EEPROM.write(0, pictureNumber + 1); // Incrementa o número para a próxima foto
EEPROM.commit(); // Salva o número da foto na EEPROM

// ... (Inicialização do cartão SD e outras configurações)
}

void loop() {
// --- Leitura de dados do GPS ---
while (SerialGPS.available() > 0)
if (gps.encode(SerialGPS.read()))
if (gps.location.isValid())
break;

// --- Atualização da tela OLED ---
display.clearDisplay();
display.setTextSize(1);
display.setTextColor(WHITE);
display.setCursor(0,0);
display.print("Lat: "); display.println(gps.location.lat(), 6);
display.print("Lng: "); display.println(gps.location.lng(), 6);
display.display();

// Capturando a imagem (configurar a função `ei_camera_capture`)
if (ei_camera_capture(EI_CLASSIFIER_INPUT_WIDTH, EI_CLASSIFIER_INPUT_HEIGHT,
snapshot_buf) == false) {
Serial.println("Failed to capture image\r\n");
return;
}

// Classificação da Imagem (configurar a função `run_classifier`)
ei::signal_t signal;
signal.total_length = EI_CLASSIFIER_INPUT_WIDTH * EI_CLASSIFIER_INPUT_HEIGHT;
signal.get_data = &ei_camera_get_data;
ei_impulse_result_t result = { 0 };

EI_IMPULSE_ERROR err = run_classifier(&signal, &result, debug_nn);
if (err != EI_IMPULSE_OK) {
ei_printf("ERR: Failed to run classifier (%d)\n", err);
return;
}

// Obtendo o resultado com maior probabilidade
float max_value = 0;
int max_index = 0;
for (size_t ix = 0; ix < EI_CLASSIFIER_LABEL_COUNT; ix++) {
if (result.classification[ix].value > max_value) {
max_value = result.classification[ix].value;
}
}
}

```

```

        max_index = ix;
    }
}
const char* predicted_label = result.classification[max_index].label;

// Salvando a Imagem no Cartão SD (criar as pastas das classes no SD Card)
String filename = "/" + String(predicted_label) + "/" + String(pictureNumber) + ".jpg";
File file = SD_MMC.open(filename, FILE_WRITE);
if (!file) {
    Serial.println("Failed to open file in writing mode");
    return;
}
file.write(snapshot_buf, EI_CAMERA_RAW_FRAME_BUFFER_COLS * EI_CAMERA_RAW_FRAME_BUFFER_ROWS * EI_CAMERA_FRAME_BYTE_SIZE);
file.close(); *
```

// --- Mostrar na tela "Foto Capturada"
display.fillRect(0, 48, SCREEN_WIDTH, 16, BLACK); // Limpa a parte inferior da tela
display.setCursor(0, 48);
display.print("Foto capturada!");
display.display();
delay(1000); // Exibe a mensagem por 1 segundo

// --- Criação/Atualização do Arquivo CSV ---
String dataString = String(gps.location.lat(), 6) + ";" +
 String(gps.location.lng(), 6) + ";" +
 gps.date.value() + ";" +
 gps.time.value() + ";" +
 String(pictureNumber) + ";" +
 String(predicted_label);

File csvFile = SD_MMC.open("/data.csv", FILE_APPEND);
if (csvFile) {
 if (pictureNumber == 1) {
 csvFile.println("latitude;longitude;data;hora;numero da foto;classificacao da foto");
 }
 csvFile.println(dataString);
 csvFile.close();
} else {
 Serial.println("Error opening data.csv");
}

// Incrementa o número da foto para a próxima captura
pictureNumber++;

// Limpa o buffer de captura de imagem
free(snapshot_buf);
delay(1000); // Ajuste este delay conforme necessário
}